MASTER ONLINE EN INTELIGENCIA ARTIFICIAL

Predicción de la dirección del S&P 500: evaluación del valor incremental del sentimiento de noticias financieras en modelos de aprendizaje automático y LSTM

TFM elaborado por: Jesús Daniel Romeral Cortina
Tutor/a de TFM: Daniel Rubio Yagüe

- El Puerto de Santa María. Marzo 2026 -

Índice

1. Resumen / Abstract 6
2. Introducción y antecedentes 8
a. Contexto general y motivación 8
b. Eficiencia de mercado y límites de enfoques tradicionales 8
c. Del aprendizaje automático al aprendizaje profundo en finanzas 8
d. Noticias financieras y análisis de sentimiento 8
e. Problemas metodológicos típicos y hueco que aborda este trabajo 9
f. Enfoque y contribución del TFM 9
g. Alcance y supuestos 9
h. Criterios de evaluación 10
i. Estructura del documento 10
3. Objetivos del proyecto 11
a. Objetivo general 11
b. Objetivos específicos 11
c. Hipótesis de trabajo 11
4. Material y métodos 12
a. Entorno de desarrollo y tecnologías 12
b. Fuentes de Datos 12
i. Datos de mercado (S&P 500) 13
ii. Corpus de noticias financieras 13
c. Preprocesado e ingeniería de características 13
i. Variables financieras 14
ii. Procesamiento de lenguaje natural (NLP) y construcción de variables 14
iii. Definición de la Variable Objetivo (Target) 15
iv. Integración y consolidación de datasets (Merge) 16
v. Selección de variables de entrada (X) para los modelos 17
d. Arquitectura de los modelos 17
i. Modelos de *Machine Learning* y proceso de optimización 17
ii. Red Neuronal Recurrente (LSTM) 18
iii. Configuración de escenarios experimentales 20
e. Control de sesgos y reproducibilidad 21
f. Métricas de evaluación 23
5. Resultados 24

a. Set de evaluación 24
b. Comparación principal: rendimiento con evaluación controlada 24
c. Ganancia incremental del sentimiento (Δ) 26
i. Cálculo de Δ. 26
ii. Resultados: horizonte 1d 27
iii. Resultados: horizonte 5d 27
iv. SIMPLE vs FULL. 27
d. Matrices de confusión y tipo de error 28
i. Resultados: horizonte 1d 28
ii. Resultados: horizonte 5d 29
iii. Cierre 30
e. Comparación ML vs LSTM por horizonte 30
i. Resultados: horizonte 1d 31
ii. Resultados: horizonte 5d 32
iii. Cierre 32
6. Conclusiones 33
a. Respuesta a la pregunta de investigación 33
b. Conclusiones por horizonte (1d vs 5d) 33
c. Conclusiones por familia de modelos (ML vs LSTM) 33
d. Conclusiones sobre escenarios (BASE vs SIMPLE vs FULL) 34
e. Contraste de hipótesis 34
f. Aportaciones del trabajo 34
g. Limitaciones 34
h. Líneas futuras 35
7. Referencias bibliográficas (APA) 36
8. ANEXOS 37

Índice de Tablas

Tabla 4-1. Escenarios experimentales. Fuente: Elaboración propia. 20

Tabla 5-1. Métricas obtenidas para cada horizonte y familia de los modelos. Fuente: elaboración propia. 24

Tabla 5-2. Deltas (SIMPLE–BASE y FULL–BASE). Fuente: Elaboración propia. 27

Tabla 5-3. Mejor modelo por (Horizonte × Familia × Escenario). Fuente: Elaboración propia..... 31

Tabla 5-4. Mejor ML vs mejor LSTM por (Horizonte × Escenario) con deltas ML−DL. Fuente elaboración propia..... 31

Tabla 8-1 Hiperparámetros finales por modelo y horizonte (ML). Fuente: Elaboración propia 37

Tabla 8-2. Hiperparámetros y configuración de entrenamiento (LSTM) Fuente: Elaboración propia 37

Tabla 8-3. Variables presentes en el dataset (no usadas como predictores). Fuente: Elaboración propia 39

Tabla 8-4. Variables técnicas (predictores en BASE/SIMPLE/FULL). Fuente: Elaboración propia.... 39

Tabla 8-5. Variables de sentimiento (SIMPLE). Fuente: Elaboración propia..... 39

Tabla 8-6. Variables de sentimiento adicionales Fuente: Elaboración propia 40

Tabla 8-7. Variables objetivo y auxiliares (no features). Fuente: Elaboración propia 40

Tabla 8-8. Disponibilidad por escenario (BASE / SIMPLE / FULL). Fuente: Elaboración propia 40

Tabla 8-9. Resultado completo métricas por experimento. Fuente: Elaboración propia..... 42

Tabla 8-10. Matrices de confusión (TN/FP/FN/TP). Fuente: Elaboración propia. 43

Tabla 8-11. Ejemplos de sentimiento diario agregado (FULL). Fuente: Elaboración propia. 45

Tabla 8-12. Titulares reales (muestra) de los días seleccionados. Fuente: Elaboración propia..... 45

Tabla 8-13. Resumen de datasets utilizados. Fuente: Elaboración propia. 46

Índice de Figuras

Figura 1. Evolución de ROC-AUC por escenario (BASE, SIMPLE, FULL) para ML y LSTM en horizonte 1d. Fuente: Elaboración propia. 25

Figura 2. Evolución de ROC-AUC por escenario (BASE, SIMPLE, FULL) para ML y LSTM en horizonte 5d. Fuente: Elaboración propia. 26

Figura 3. Matrices confusión. Horizonte 1d (BASE vs SIMPLE). Fuente: Elaboración propia..... 29

Figura 4. Matrices de confusión (Horizonte 5d, BASE vs SIMPLE). Fuente: Elaboración propia..... 30

1. Resumen / Abstract

Este Trabajo Fin de Máster analiza si la incorporación de variables de sentimiento extraídas de titulares financieros mejora la predicción de la dirección del índice S&P 500, planteada como un problema de clasificación binaria. Para ello, se comparan tres escenarios: BASE, formado solo por variables financieras derivadas de retornos; SIMPLE, que añade una medida diaria resumida del sentimiento junto con el volumen de noticias; y FULL, que incorpora además información más detallada sobre la variación del sentimiento y la proporción de noticias positivas y negativas. La comparación se realiza manteniendo constantes el particionado temporal, el preprocesado y la configuración de los modelos en cada horizonte, con el fin de que las diferencias observadas respondan al conjunto de variables utilizado.

Las variables de sentimiento se obtienen con FinBERT y se agregan a nivel diario para poder integrarlas con la serie de mercado. Además, se tiene en cuenta la existencia de días sin noticias mediante indicadores específicos e imputación neutral. En el estudio se comparan modelos de Machine Learning, incluyendo un *baseline* Dummy y varios clasificadores tabulares, junto con una arquitectura LSTM. La evaluación se lleva a cabo en los horizontes *t+1* y *t+5* utilizando métricas que permiten valorar tanto el acierto global como la capacidad discriminativa del modelo, con especial atención a Balanced Accuracy y ROC-AUC.

Los resultados muestran que el efecto del sentimiento no es uniforme, sino que depende tanto del horizonte de predicción como del tipo de modelo. En el horizonte de 1 día, su aportación es limitada en los modelos tabulares y más visible en LSTM. En cambio, en 5 días, la mejora se aprecia principalmente en los modelos tabulares al incorporar variables de sentimiento, mientras que en LSTM el comportamiento resulta menos estable según la métrica considerada.

Palabras clave: S&P 500, análisis de sentimiento, FinBERT, estudio de ablación, LSTM, series temporales financieras, ROC-AUC.

Abstract (EN)

This Master's Thesis examines whether incorporating sentiment variables extracted from financial headlines improves the prediction of the S&P 500 index direction, framed as a binary classification problem. To this end, three scenarios are compared: BASE, which includes only financial variables derived from returns; SIMPLE, which adds a daily summary measure of sentiment together with news volume; and FULL, which further incorporates more detailed information on sentiment variation and the proportion of positive and negative news. The comparison is carried out while keeping the temporal split, preprocessing, and model configuration constant for each horizon, so that the observed differences can be attributed to the set of input variables used.

The sentiment variables are obtained using FinBERT and aggregated at the daily level in order to integrate them with the market time series. In addition, days without news are explicitly considered through specific indicators and neutral imputation. The study compares Machine Learning models, including a Dummy baseline and several tabular classifiers, together with an LSTM architecture. The evaluation is performed for the t+1 and t+5 horizons using metrics that capture both overall predictive accuracy and the model's discriminative ability, with particular attention to Balanced Accuracy and ROC-AUC.

The results show that the effect of sentiment is not uniform, but depends on both the prediction horizon and the type of model. In the 1-day horizon, its contribution is limited in tabular models and more noticeable in LSTM. By contrast, in the 5-day horizon, the improvement is observed mainly in tabular models when sentiment variables are incorporated, whereas in LSTM the behavior is less stable depending on the metric considered.

Keywords: S&P 500, sentiment analysis, FinBERT, ablation study, LSTM, financial time series, ROC-AUC.

2. Introducción y antecedentes

a. Contexto general y motivación

El S&P 500 es uno de los índices más utilizados como referencia del mercado de renta variable estadounidense, ya que agrupa empresas de gran capitalización y ofrece una visión bastante representativa de su evolución. Además, dispone de series históricas amplias y homogéneas, por lo que se usa con frecuencia en trabajos de predicción financiera y análisis de series temporales.

No obstante, predecir movimientos bursátiles a corto plazo es una tarea compleja. La señal predictiva suele ser limitada, los patrones no permanecen estables en el tiempo y la relación entre la información disponible y el comportamiento del precio puede variar según el contexto de mercado. Por ello, más que centrarse en aciertos puntuales, resulta fundamental evaluar el rendimiento fuera de muestra mediante un esquema temporal adecuado y con medidas explícitas para evitar sesgos. (López de Prado, 2018)

b. Eficiencia de mercado y límites de enfoques tradicionales

La Hipótesis del Mercado Eficiente (EMH) sostiene que los precios recogen rápidamente la información disponible, por lo que resulta difícil obtener ventajas sistemáticas utilizando señales públicas. Aun así, incluso si se parte de un mercado generalmente eficiente, sigue teniendo interés estudiar si existen ciertos contextos en los que puede aparecer algo de predictibilidad. La atención de los inversores no es constante, la difusión de la información puede no ser inmediata y la interpretación de las noticias no siempre genera la misma reacción ni en el mismo momento. Así, más que discutir si el mercado es plenamente predecible, resulta más razonable estudiar si cierta información pública puede añadir capacidad predictiva cuando se analiza con un procedimiento metodológico adecuado (Fama, 1970; Lo, 2004).

c. Del aprendizaje automático al aprendizaje profundo en finanzas

En problemas de clasificación direccional (subida/bajada), los modelos tabulares de *machine learning* (por ejemplo, regresión logística, árboles o técnicas de *boosting*) se usan con frecuencia porque suelen dar un buen equilibrio entre rendimiento, interpretabilidad y coste computacional. Y además, cuando se acompañan con una buena ingeniería de variables (retornos, volatilidad, medias móviles, etc.) pueden captar relaciones no lineales de forma bastante eficaz.

El punto débil habitual es que estos modelos tratan cada día como un “vector” de características y no modelan de forma explícita la secuencia temporal. Para capturar dependencias en el tiempo se han explorado redes recurrentes como las LSTM, que emplean mecanismos de compuertas para aprender patrones a lo largo de varias observaciones (Hochreiter & Schmidhuber, 1997). En este sentido, comparar enfoques tabulares y secuenciales es especialmente útil cuando el diseño experimental controla con cuidado qué información entra en cada modelo.

d. Noticias financieras y análisis de sentimiento

Las noticias financieras no solo informan sobre lo que ha ocurrido, sino que también transmiten un tono más positivo o más negativo y, en muchos casos, cierto grado de incertidumbre. Todo ello puede influir en las expectativas de los inversores y en su forma de reaccionar en el mercado. Por esta razón, distintos trabajos han estudiado la relación entre el tono de las noticias y diversas

variables financieras, planteando que el texto puede aportar información complementaria a la que recogen los datos puramente numéricos.

Además, el lenguaje utilizado en el ámbito financiero presenta matices propios. Por eso, los diccionarios o modelos generalistas no siempre interpretan correctamente determinadas expresiones frecuentes en este contexto, y se han desarrollado recursos específicos para este dominio (Loughran y McDonald, 2011). Más recientemente, los modelos basados en Transformers han permitido avanzar desde enfoques más simples, centrados en recuentos de palabras, hacia métodos que tienen en cuenta el contexto. En este marco, FinBERT se utiliza como una herramienta especializada para estimar el sentimiento financiero de una forma más ajustada al significado del texto (Devlin, Chang, Lee y Toutanova, 2019; Araci, 2019).

e. Problemas metodológicos típicos y hueco que aborda este trabajo

En predicción financiera no es difícil obtener resultados aparentemente buenos que después no se mantienen al evaluar fuera de muestra. Entre los problemas más habituales están, por un lado, las comparaciones poco controladas entre modelos con y sin información textual, cuando al mismo tiempo también cambian los hiperparámetros, el preprocesado o la forma de validar. Por otro lado, aparecen con frecuencia problemas de fuga temporal (*look-ahead bias/data leakage)*, ya sea por particiones mal planteadas o por la ingeniería de variables de manera que terminan incorporando información futura. Además, cuando se añaden muchas variables sin un criterio claro, aumenta el riesgo de introducir ruido y de obtener resultados menos estables fuera de muestra.

Este TFM se plantea precisamente desde esa preocupación metodológica. Más que buscar el modelo con el mejor resultado posible, el objetivo es analizar si el sentimiento aporta una mejora real dentro de un diseño controlado y comparable.

f. Enfoque y contribución del TFM

El trabajo parte de una pregunta concreta: comprobar si el sentimiento extraído de los titulares financieros puede aportar información útil para predecir la dirección diaria del S&P 500.

Para responder a esa cuestión, se plantea una comparación en la que lo que cambia entre escenarios es el conjunto de variables de entrada, mientras que el resto del procedimiento se mantiene estable en cada horizonte. En concreto, se diferencian tres escenarios: BASE, con variables exclusivamente financieras; SIMPLE, que añade un resumen diario del sentimiento y el volumen de noticias; y FULL, que incorpora además información más detallada sobre la variación del sentimiento y la proporción de noticias positivas y negativas. A partir de esta estructura, se analiza el efecto del sentimiento en dos familias de modelos, los clasificadores tabulares de *machine learning* y una arquitectura LSTM, tanto en el horizonte de 1 día como en el de 5 días.

g. Alcance y supuestos

El problema se plantea como una clasificación binaria (subida/bajada) a nivel diario. La información textual se incorpora mediante variables agregadas por día, por lo que no se modela la dinámica intradiaria ni se tiene en cuenta el momento exacto de publicación de cada noticia. El objetivo principal es medir si el sentimiento aporta valor predictivo incremental bajo un protocolo temporal fuera de muestra, más que construir una estrategia operativa completa.

h. Criterios de evaluación

Teniendo en cuenta el posible desbalance entre clases y el carácter direccional del problema, se utiliza un conjunto de métricas complementarias, como Accuracy, Balanced Accuracy y ROC-AUC. Con ellas se pretende evaluar tanto el acierto con un umbral fijo como la capacidad del modelo para discriminar entre clases.

i. Estructura del documento

El resto del documento se organiza así: el capítulo 3 presenta los objetivos e hipótesis; el capítulo 4 describe los datos, la construcción de variables y el diseño experimental; el capítulo 5 muestra y compara los resultados; el capítulo 6 resume las conclusiones, limitaciones y posibles líneas futuras; y el capítulo 7 recoge la bibliografía.

3. Objetivos del proyecto

a. Objetivo general

Analizar si la incorporación de variables de sentimiento obtenidas a partir de titulares de noticias financieras mejora la predicción de la dirección diaria del índice S&P 500 (subida/bajada). Para ello, se comparan de forma controlada modelos tabulares de *machine learning* y una arquitectura secuencial LSTM en horizontes de 1 día y 5 días, dentro de un diseño experimental común.

b. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- Construir un conjunto de datos reproducible del S&P 500 y generar variables derivadas adecuadas para un problema de clasificación supervisada.
- Procesar el corpus de noticias y obtener variables de sentimiento a frecuencia diaria mediante un modelo NLP específico del dominio (p. ej., FinBERT), incluyendo un tratamiento explícito de los días sin noticias.
- Definir el objetivo predictivo en horizontes *t+1* y *t+5*, asegurando la alineación temporal entre variables en *t* y etiquetas futuras para evitar sesgos de anticipación.
- Diseñar una comparación por escenarios de información (BASE, SIMPLE, FULL) que permita aislar el efecto del sentimiento manteniendo constante el resto del esquema experimental.
- Entrenar y evaluar modelos tabulares de referencia (incluyendo un *baseline* tipo Dummy y clasificadores de ML) y un modelo secuencial LSTM bajo los mismos horizontes y escenarios.
- Evaluar el rendimiento con métricas complementarias (especialmente Balanced Accuracy y ROC-AUC) y analizar en qué condiciones el sentimiento aporta señal incremental, señalando limitaciones y posibles mejoras.

c. Hipótesis de trabajo

Con el fin de orientar el análisis, se proponen las siguientes hipótesis:

- H1 (Valor incremental del sentimiento). La incorporación de variables de sentimiento puede mejorar la capacidad predictiva del modelo frente a un escenario basado únicamente en variables financieras.
- H2 (Dependencia del horizonte). El efecto del sentimiento no tiene por qué ser el mismo en todos los horizontes de predicción, por lo que su aportación puede variar entre 1 día y 5 días.
- H3 (Interacción con la familia de modelos). La utilidad de las variables de sentimiento puede depender también del tipo de modelo empleado, de manera que su efecto no sea igual en modelos tabulares de *machine learning* y en una arquitectura LSTM.

Estas hipótesis se evaluarán comparando los escenarios BASE, SIMPLE y FULL en los horizontes de 1 día y 5 días, manteniendo constante el resto del diseño experimental para que las diferencias observadas puedan interpretarse de forma coherente y comparable.

4. Material y métodos

En este capítulo se describen los datos, las herramientas y el procedimiento seguido para desarrollar el experimento. Se explica el preprocesado de la serie histórica del S&P 500, la obtención de variables de sentimiento a partir de noticias financieras y la construcción de los modelos en tres escenarios: BASE (sin variables de sentimiento), SIMPLE (con un resumen reducido del sentimiento) y FULL (con una agregación más completa). Todo ello se plantea con una validación temporal estricta, para que la comparación entre escenarios permita analizar de la forma más consistente posible el efecto de incorporar información procedente de noticias.

a. Entorno de desarrollo y tecnologías

Los experimentos se han realizado en un entorno local con Visual Studio Code y Jupyter Notebooks, utilizando Python 3.x como lenguaje principal. Para llevar a cabo el trabajo se han empleado distintas librerías del ecosistema científico de Python, orientadas a la preparación de datos, el análisis de series temporales, la extracción de sentimiento, el entrenamiento de modelos y la evaluación de resultados. A continuación, se resumen las herramientas principales utilizadas:

- Gestión del proyecto y persistencia: se ha utilizado os para organizar rutas y gestionar los archivos generados, como datasets procesados, figuras y resultados. Además, se ha empleado json para guardar configuraciones experimentales e hiperparámetros, facilitando la repetición de ejecuciones por horizonte y escenario.
- Manipulación y análisis de datos: pandas y numpy se han empleado para la limpieza de datos, el tratamiento de series temporales y la construcción de variables.
- Adquisición de datos financieros: yfinance se ha utilizado para automatizar la descarga de la serie histórica del S&P 500 (OHLCV), manteniendo un proceso de obtención de datos replicable.
- Procesamiento de lenguaje natural y sentimiento: se han integrado transformers (Hugging Face) y torch para ejecutar un modelo preentrenado del dominio financiero, FinBERT, con el que se estima el sentimiento de los titulares y se construyen variables agregadas con frecuencia diaria.
- Modelos de *machine learning* tabular: scikit-learn se ha usado para el preprocesado, entrenamiento y evaluación de modelos clásicos. En concreto, se han empleado StandardScaler, modelos de referencia (DummyClassifier) y clasificadores como LogisticRegression, RandomForestClassifier e HistGradientBoostingClassifier, además de utilidades de validación y ajuste de hiperparámetros (TimeSeriesSplit, GridSearchCV y *Pipeline*).
- Modelos de deep learning: tensorflow/keras se ha utilizado para definir y entrenar redes LSTM, incorporando regularización y callbacks de control del entrenamiento (EarlyStopping y ReduceLROnPlateau) para mejorar la estabilidad del ajuste y reducir el sobreentreno.
- Visualización: la exploración y presentación de resultados se ha realizado principalmente con matplotlib.

b. Fuentes de Datos

El estudio se apoya en dos fuentes principales: (i) una serie diaria del índice S&P 500 para describir el comportamiento del mercado y (ii) un corpus de titulares financieros del que se extraen variables de sentimiento agregadas a nivel diario. Esta combinación permite comprobar, con un diseño controlado, si la información textual aporta una mejora en la predicción frente al uso exclusivo de variables financieras históricas.

i. Datos de mercado (S&P 500)

Los datos históricos de cotización del índice Standard & Poor's 500 se obtuvieron desde Yahoo Finance mediante la librería yfinance, lo que permite automatizar la descarga y mantener un procedimiento replicable (Aroussi, 2026; Yahoo Finance, s. f.).

Se utilizó el ticker ^GSPC, con frecuencia diaria y un rango inicial de 15 años desde 2010, guardando el resultado en el archivo sp500_ohlcv_2010_2025.csv (Notebook NB01a).

Tras la limpieza y conversión de tipos, la serie final utilizada para el modelado se recortó al periodo 2013-01-02 a 2024-03-04 para asegurar la compatibilidad temporal con el rango empleado en la integración de noticias. (Notebooks NB01a/NB01b). El inventario consolidado de ficheros finales (rangos temporales y tamaños) se recoge en el Anexo VI (Tabla 8.13).

El dataset financiero final se guarda como sp500_model.csv e incluye variables como Date, Open, High, Low, Close y Volume, además de variables derivadas (retornos, rezagos y estadísticas móviles) y las etiquetas objetivo definidas para horizontes de 1 y 5 días (apartado 4.c.iii).

ii. Corpus de noticias financieras

Para incorporar la dimensión informativa del mercado se empleó un dataset público disponible en Kaggle, almacenado como sp500_news_kaggle.csv. Este corpus proporciona titulares periodísticos asociados a fechas, lo que permite transformar el contenido textual en variables cuantitativas de sentimiento e integrarlas posteriormente con la serie financiera (Dasmahaptra, s. f.).

Se eligió un dataset estático frente a la extracción mediante proveedores comerciales o APIs (p. ej., Bloomberg Terminal, Refinitiv, NewsAPI) por dos motivos principales:

- Viabilidad y acceso: el acceso a históricos de noticias de alta calidad suele requerir licencias de coste elevado o impone limitaciones en planes gratuitos, lo que dificulta un análisis de largo plazo en un contexto académico.
- Reproducibilidad: al ser un corpus público y cerrado, los experimentos pueden repetirse bajo las mismas condiciones, evitando cambios derivados de contenidos dinámicos.

El dataset contiene 19.127 titulares con su fecha (Date) y cubre el periodo 2008-01-02 a 2024-03-04 (Dasmahaptra, s. f.). Como limitación, la densidad de noticias no es homogénea: hay días con pocas noticias e incluso sesiones sin titulares, especialmente en los primeros años. Por ello, durante el preprocesado se aplican estrategias de agregación diaria y un tratamiento específico de los días sin noticias para mantener la continuidad temporal y la comparabilidad entre escenarios (apartado 4.c.ii).

El tratamiento de días sin noticias y las imputaciones empleadas se detallan en el apartado 4.c.iv y se ilustran con ejemplos reales en el Anexo IV (Tablas 8.11–8.12).

Como resultado del procesamiento NLP se generan dos datasets diarios:

- sentiment_daily.csv (escenario SIMPLE)
- sentiment_daily_FULL.csv (escenario FULL)

c. Preprocesado e ingeniería de características

El preprocesado se organizó en cuatro bloques: (i) ingeniería de variables financieras, (ii) extracción y agregación del sentimiento, (iii) definición del objetivo para horizontes de 1 día y 5 días y (iv) integración de ambas fuentes por fecha. A partir de estos pasos, se define el conjunto de variables de entrada X para cada escenario experimental.

i. Variables financieras

A partir de la serie OHLCV diaria se realiza una preparación inicial (unificación de nombres de columnas, conversión de tipos numéricos y ordenación temporal) y se construye un conjunto de variables pensado para capturar la dinámica reciente sin incorporar información futura. Las columnas OHLCV se conservan como registro, pero no se usan como predictores (ver Anexo II, Tabla 8.3). Sobre esta base se generan las siguientes variables técnicas:

- Retorno diario ($Return_t$): calculado sobre el precio de cierre:

$$Return_t = \left(\frac{Close_t}{Close_{\{t-1\}}}\right) - 1$$

- Lags de retornos: ret_lag_1 a ret_lag_5, que incorporan "memoria" corta de hasta una semana bursátil.
- Medias móviles de retornos: medias (ret_ma_5, ret_ma_10) que actúan como suavizado para aproximar la tendencia subyacente frente al ruido diario.
- Desviaciones estándar (ret_std_5, ret_std_10) como aproximaciones de tendencia/ruido y volatilidad reciente.

Tal y como anteriormente se comentó, para asegurar coherencia temporal con el estudio y compatibilidad con el corpus de noticias, la serie se recortó al intervalo 2013-01-02 a 2024-03-04 y se guardó como sp500_model.csv (Notebook NB01b). El diccionario completo de variables técnicas y su definición formal se incluye en el Anexo II (ver Tabla 8.4)

ii. Procesamiento de lenguaje natural (NLP) y construcción de variables

Para cuantificar el tono informativo de los titulares se utilizó FinBERT-tone (yiyanghkust/finbert-tone), un modelo Transformer especializado en lenguaje financiero, implementado con la librería Hugging Face Transformers (Notebook NB01c). (yiyanghkust, s. f.; Huang, Wang y Yang, 2023; Wolf et al., 2020)

En este bloque, los titulares financieros se transforman en variables numéricas agregadas a nivel diario, para poder integrarlas con la serie temporal del S&P 500.

Limpieza y normalización del corpus (preprocesado mínimo):

- Conversión de Date a datetime y eliminación de registros con fecha no válida.
- Construcción de un campo text a partir de Title, normalizando a cadena y eliminando entradas vacías.
- Eliminación de duplicados exactos por (Date, text) para evitar doble conteo en la agregación diaria.

Inferencia de sentimiento por titular

La inferencia se realizó con Hugging Face Transformers, empleando AutoTokenizer y AutoModelForSequenceClassification integrados mediante *pipeline*("sentiment-analysis") con el modelo FinBERT-tone. (Wolf et al., 2020)

Para cada titular, el modelo devuelve una etiqueta (positive, negative, neutral) y una puntuación asociada (score). Para disponer de una señal continua con signo, se definió:

$$sentiment_signed = sign(label) \times score$$

donde positive = +1, negative = -1 y neutral = 0, quedando el valor final acotado en [-1, 1] e incorporando dirección e intensidad/confianza.

Inferencia por lotes (batching)

Dado el volumen de titulares, la predicción se ejecutó en lotes (batch_size = 32) para mejorar la eficiencia y controlar el consumo de recursos, monitorizando el progreso con tqdm.

Agregación diaria y construcción de variantes (SIMPLE vs FULL)

Como puede existir más de un titular por día, el sentimiento se agregó a nivel diario para generar dos versiones del dataset:

- SIMPLE (sentiment_daily.csv): sentiment_mean (media diaria de sentiment_signed) y n_news (número de titulares del día).
- FULL (sentiment_daily_FULL.csv): incluye lo anterior y añade sentiment_median, sentiment_std y pos_ratio, neg_ratio, neu_ratio, definidas como las proporciones diarias de cada clase.

De este modo, puede compararse una versión más sencilla con otra más completa, para comprobar si añadir más variables aporta información útil o, por el contrario, introduce más ruido.

Las variables de sentimiento utilizadas en los escenarios SIMPLE y FULL, junto con sus definiciones y reglas prácticas de imputación, se recogen en el Anexo II (Tablas 8.5–8.6)

iii. Definición de la Variable Objetivo (Target)

El objetivo del proyecto es predecir la dirección del mercado como un problema de clasificación binaria (subida frente a bajada). Para analizar el rendimiento tanto en movimientos a muy corto plazo como en señales algo más sostenidas, se definieron dos horizontes temporales:

Target_1d (t): toma valor 1 si el retorno del día siguiente es positivo y 0 en caso contrario:

$$Target_{1d}(t) = 1[Return_t > 0]$$

donde:

$$Return_t = \left(\frac{Close_t}{Close_{\{t-1\}}}\right) - 1$$

Target_5d (t): toma valor 1 si el retorno acumulado a 5 sesiones es positivo y 0 en caso contrario:

$$Target_{5d}(t) = 1[Return_5d_forward(t) > 0]$$

donde:

$$Return_5d_forward(t) = \frac{Close_{t+5}}{Close_t} - 1$$

La definición de targets y variables auxiliares forward (no utilizadas como predictores) se resume en el Anexo II (Tabla 8.7).

Alineación temporal y prevención de *look-ahead bias*

Las etiquetas se definen a partir de información futura (*t+1* o *t+5*) por definición del problema, pero se garantiza que las variables explicativas utilizadas por el modelo correspondan únicamente a

información disponible hasta el instante *t*. En la implementación, esto se materializa mediante el desplazamiento temporal (*shifting*) de las etiquetas, asociando las características del día *t* con el resultado observado en *t+1* o *t+5*.

iv. Integración y consolidación de datasets (Merge)

Una vez generadas por separado las variables financieras y las variables de sentimiento, ambas fuentes se integraron para construir los datasets finales de entrenamiento y evaluación. En este punto, resulta importante mantener una alineación temporal correcta entre fechas para evitar errores en la unión de la información.

Normalización de la clave temporal (Date)

Antes de la unión, se convirtió la columna Date a tipo fecha y se normalizó al inicio del día (misma granularidad diaria) tanto en el dataset financiero como en los datasets de sentimiento. Esto garantiza que ambas fuentes se unan de forma consistente por jornada.

Sincronización y tipo de unión (*join*)

La integración se realizó mediante un *left join* por Date, tomando el dataset financiero como base para conservar todas las sesiones de mercado y añadir el sentimiento cuando existiera información disponible.

Alineación temporal del sentimiento (*Lag* 0)

Se utilizó una alineación por fecha (*lag* 0), considerando el sentimiento asociado a la fecha t como una variable exógena disponible para la predicción en horizontes *t+1* y *t+5*. Dado que no se dispone de timestamp intradía, la alineación se realiza por fecha calendario.

Tratamiento de días sin noticias (valores ausentes tras el *merge*)

Tras la unión aparecen valores faltantes en las variables de sentimiento para sesiones sin titulares asociados. Para gestionarlo sin eliminar sesiones de mercado, se definieron (apartado e):

- has_news: indicador binario (1 si existe n_news, 0 si no).
- sentiment_filled: imputación neutra (sentiment_mean ausente (NA) se sustituye por 0).
- n_news_filled: imputación (n_news ausente se sustituye por 0).

En el caso del escenario FULL, el resto de variables (sentiment_median, sentiment_std, pos_ratio, neg_ratio, neu_ratio) se imputan a 0 cuando no hay noticias. El indicador has_news permite distinguir entre ausencia de noticias y valores neutrales reales.

Como resultado, se consolidaron las variantes utilizadas en la comparativa:

- BASE: sp500_model.csv (solo variables financieras).
- SIMPLE: sp500_sent_model.csv variables Financieras + (sentiment_mean, n_news) + variables derivadas (has_news, sentiment_filled, n_news_filled).
- FULL: sp500_sent_FULL.csv variables financieras + métricas extendidas (sentiment_median, sentiment_std, pos_ratio, neg_ratio, neu_ratio) + has_news e imputaciones.

Los ficheros finales generados por escenario y su resumen se recogen en el Anexo VI (Tabla 8.13).

v. Selección de variables de entrada (X) para los modelos

Aunque el dataset base conserva las columnas OHLCV (Open, High, Low, Close, Volume) como parte del registro, en la fase de entrenamiento estas se excluyen del conjunto de variables explicativas, junto con las variables objetivo y cualquier magnitud forward asociada al horizonte, para evitar fuga de información y mantener una comparación consistente entre modelos. En concreto, para construir X se eliminan: Target_1d, Target_5d, Return_5d_forward y las columnas OHLCV. Se mantienen como predictores las variables derivadas de retornos (*lags* y estadísticas móviles) y, cuando procede, las variables de sentimiento según el escenario experimental.

En los escenarios con sentimiento, se utilizan las variables imputadas (sentiment_filled, n_news_filled) junto con has_news, para evitar valores ausentes. Esta misma regla de selección de X se aplica tanto en los modelos tabulares como en LSTM, y en ambos horizontes (1d y 5d).

La disponibilidad de variables por escenario (BASE/SIMPLE/FULL) se resume en el Anexo II (Tabla 8.8).

d. Arquitectura de los modelos

En esta sección se describen los modelos utilizados para predecir la dirección del S&P 500 y el criterio seguido para su configuración experimental. Se comparan dos enfoques: (i) modelos de *Machine Learning* sobre variables tabulares, financieras y, cuando corresponde, de sentimiento; y (ii) un modelo de Deep Learning basado en redes recurrentes LSTM, orientado al análisis de dependencias temporales mediante ventanas secuenciales.

Todos los modelos se entrenan y evalúan para dos horizontes temporales (1 día y 5 días) y en tres escenarios de variables:

- BASE: solo variables financieras (dataset sp500_model.csv).
- SIMPLE: variables financieras + sentimiento agregado básico (sp500_sent_model.csv).
- FULL: variables financieras + sentimiento agregado extendido (sp500_sent_FULL.csv).

Con el fin de asegurar una comparativa justa, el procedimiento de particionado temporal, preprocesado y evaluación se mantiene constante dentro de cada horizonte, variando únicamente el conjunto de variables de entrada según el escenario.

i. Modelos de *Machine Learning* y proceso de optimización

Modelos seleccionados

Se emplearon cuatro modelos tabulares, cubriendo desde baselines sencillos hasta métodos no lineales de ensamble:

- DummyClassifier (most_frequent): baseline de referencia que predice la clase mayoritaria, utilizado para verificar que los modelos propuestos superan un rendimiento trivial.
- Regresión logística: baseline lineal que estima la probabilidad de subida/bajada a partir del conjunto de variables de entrada. Se utiliza además como referencia interpretable frente a modelos no lineales.
- Random Forest: modelo de ensamble tipo bagging que permite capturar relaciones no lineales e interacciones entre variables, generalmente robusto frente al ruido en datos tabulares.
- HistGradientBoostingClassifier: método de gradient boosting eficiente para datos tabulares, que aprende de forma iterativa corrigiendo errores previos y suele rendir bien en problemas con variables derivadas.

Optimización con validación temporal (solo en BASE)

La búsqueda de hiperparámetros se realiza únicamente en el escenario BASE mediante GridSearchCV y validación cruzada temporal (TimeSeriesSplit con 5 particiones). De este modo, se respeta el orden cronológico de la serie y se reduce el riesgo de fuga temporal. El criterio de selección utilizado es ROC-AUC (scoring="roc_auc"). Esta fase se ejecuta de forma independiente para cada horizonte (1d y 5d), utilizando el dataset correspondiente. (NB02a para 1d y NB02b para 5d).

Los hiperparámetros finales seleccionados por modelo y horizonte se recogen en el Anexo I (Tabla 8.1)

Uso de los mismos hiperparámetros en escenarios con sentimiento

Para poder atribuir cualquier diferencia de rendimiento a la incorporación de variables de sentimiento (y no a cambios en la complejidad del modelo), los hiperparámetros seleccionados en BASE se guardan por horizonte en ficheros de configuración (best_params_ml_1d.json y best_params_ml_5d.json). Posteriormente, estos hiperparámetros se reutilizan sin retuning en los escenarios SIMPLE y FULL (NB03a/NB03b y NB04a/NB04b, respectivamente).

Configuración de modelos (resumen)

- DummyClassifier: strategy="most_frequent".
- Regresión logística: max_iter=1000, class_weight="balanced" y, como parámetros optimizados por horizonte, C y solver.
- Random Forest: max_features="sqrt", class_weight="balanced", n_jobs=-1, random_state=42 y, como parámetros optimizados por horizonte, n_estimators, max_depth y min_samples_leaf.
- HistGradientBoostingClassifier: random_state=42 y, como parámetros optimizados por horizonte, learning_rate, max_depth y min_samples_leaf.

Preprocesado y escalado

La estandarización mediante StandardScaler se aplica únicamente en regresión logística. En los modelos basados en árboles (Random Forest y HistGradientBoostingClassifier) no se utiliza escalado al no ser necesario para este tipo de algoritmos.

Nota sobre control temporal y prevención de leakage

Dado que el objetivo se define con horizontes a H días vista (H=1 o H=5), se aplican medidas explícitas para evitar fuga temporal tanto en el particionado train/test como durante la validación temporal en la búsqueda de hiperparámetros. Estas medidas (embargo de H observaciones y uso de gap=H en TimeSeriesSplit) se describen de forma detallada en el apartado e) Control de sesgos y reproducibilidad.

ii. Red Neuronal Recurrente (LSTM)

Con el objetivo de capturar dependencias temporales y patrones secuenciales en la serie, se implementó un modelo de red neuronal recurrente tipo LSTM como aproximación de Deep Learning. El entrenamiento se realizó para ambos horizontes de predicción (1 día y 5 días) y en los tres escenarios experimentales definidos en el trabajo (BASE, SIMPLE y FULL), manteniendo el

mismo protocolo de partición temporal, preprocesado y evaluación para asegurar comparabilidad entre experimentos (notebooks NB02c/NB02d, NB03c/NB03d, NB04c/NB04d).

Preparación de entradas secuenciales (lookback)

Dado que las LSTM requieren entradas en forma de secuencias, las variables se transformaron mediante un enfoque de ventanas deslizantes (sliding window). Se definió un lookback = 10 sesiones, de modo que cada muestra incorpora la información de los 10 días previos. Tras la transformación, las entradas adoptan la forma: (n_muestras, lookback, n_features) donde n_features depende del escenario (BASE/SIMPLE/FULL).

Por construcción, las primeras 10 observaciones de cada partición no generan muestra al no disponer de histórico suficiente.

La arquitectura LSTM empleada se resume visualmente en el Anexo I (Tabla 8.2)

Escalado sin fuga de información

Las características numéricas se estandarizaron con StandardScaler, ajustando el escalador únicamente con el conjunto de entrenamiento y aplicándolo después a validación y test. El escalado se realiza antes de construir las secuencias, de manera que todas las variables mantienen una escala coherente sin incorporar información del periodo de prueba.

Partición temporal y validación interna (train/val) para entrenamiento

En el caso de redes LSTM se reservó una fracción final del conjunto de entrenamiento como validación interna para monitorizar el aprendizaje mediante callbacks (parada temprana y ajuste de tasa de aprendizaje), manteniendo un enfoque temporal (sin barajado). Esta validación interna se utiliza exclusivamente durante el entrenamiento y no sustituye al conjunto de *prueba out-of-sample*, que permanece completamente separado para la evaluación final.

Arquitectura del modelo

Se utilizó una arquitectura secuencial compacta con regularización para reducir el riesgo de sobreajuste:

- Entrada: (lookback, n_features)
- Capa LSTM(NEURONAS) con regularización L2 = 1e-4
- Dropout(0.2)
- Capa Dense(NEURONAS/2, ReLU) con L2 = 1e-4
- Dropout(0.2)
- Salida: Dense(1, activación sigmoid) para clasificación binaria (subida/bajada)

Configuración de entrenamiento y callbacks

- Optimizador: Adam con learning_rate = 1e-3
- Función de pérdida: binary_crossentropy
- Métricas durante entrenamiento: accuracy y ROC-AUC (AUC-ROC)

- epochs = 100, batch_size = 32
- EarlyStopping monitorizando val_roc_auc (modo max), con patience = 10 y restore_best_weights = True.
- ReduceLROnPlateau monitorizando val_roc_auc (modo max), con factor = 0.5, patience = 5 y min_lr = 1e-5.

La configuración completa (lookback, regularización, callbacks y parámetros de entrenamiento) se detalla en el Anexo I (Tabla 8.2)

Selección de NEURONAS y consistencia experimental

Para controlar la complejidad del modelo y mantener el mismo criterio entre escenarios, se evaluaron variantes con distinto tamaño de la capa LSTM, manteniendo fijo el resto de hiperparámetros y el protocolo de validación. En los experimentos se consideraron tamaños reducidos, como 32 y 64 neuronas, suficientes para comparar el efecto de incorporar variables de sentimiento frente al escenario sin sentimiento.

Regla de decisión y evaluación

La salida del modelo se interpreta como probabilidad de clase positiva (subida). Para obtener la predicción binaria se utiliza el umbral estándar 0.5. La evaluación final se realiza sobre el conjunto de prueba *out-of-sample* mediante: Accuracy, Balanced Accuracy, Precision, Recall, F1 y ROC-AUC, además de la matriz de confusión para interpretar el tipo de error.

iii. Configuración de escenarios experimentales

Se definieron tres escenarios experimentales: BASE, SIMPLE y FULL. La comparación se realiza manteniendo constante el horizonte (1d y 5d), el particionado temporal y el protocolo de evaluación, de modo que el cambio principal entre escenarios sea el conjunto de variables de entrada, y con ello el dataset utilizado.

Tabla 4-1. Escenarios experimentales. Fuente: Elaboración propia.

Escenario	Archivo	Descripción	Variables de Sentimiento
BASE	sp500_model.csv	Solo variables financieras (retornos y derivados: lags, medias móviles, volatilidad, etc.)	—
SIMPLE	sp500_sent_model.csv	Variables financieras + sentimiento agregado básico	sentiment_mean, n_news y tratamiento de ausencia de noticias: has_news, sentiment_filled, n_news_filled

FULL	sp500_sent_FULL.csv	Variables financieras + sentimiento agregado extendido	SIMPLE + métricas adicionales de sentimiento: sentiment_median, sentiment_std, pos_ratio, neg_ratio, neu_ratio

Sentido de la comparación entre escenarios

Estos escenarios permiten comparar un enfoque sin información textual (BASE) con dos variantes que incorporan sentimiento: una versión más sencilla (SIMPLE) y otra más completa (FULL). En todos los casos se mantiene la misma definición del target para cada horizonte, el mismo esquema de particionado temporal y la misma metodología de evaluación, para que las diferencias observadas puedan interpretarse en función de las variables utilizadas.

e. Control de sesgos y reproducibilidad

En problemas financieros, pequeñas fugas de información (*data leakage*) o decisiones de validación poco adecuadas pueden dar una impresión de rendimiento mejor de la real. Por ello, este trabajo incorpora varias medidas orientadas a reducir los sesgos más habituales en series temporales y a mantener un procedimiento estable en los distintos horizontes y escenarios.

Prevención de *look-ahead bias* y *data leakage*

- Alineación temporal del objetivo (label shifting): las etiquetas se definen como un resultado futuro (t+1 o t+5), pero las variables explicativas utilizadas por el modelo corresponden solo a información disponible hasta t.
- Ingeniería de variables sin anticipación: lags, medias móviles y medidas de volatilidad se calculan únicamente con histórico disponible hasta t (sin usar información futura).
- Eliminación de variables con señales triviales: para evitar dependencias directas con el precio, se eliminan de X las columnas OHLCV (Open, High, Low, Close, Volume) y se trabaja sobre retornos y variables derivadas (lags y estadísticas móviles).
- Exclusión de columnas objetivo y magnitudes forward: se excluyen Target_1d, Target_5d y variables "adelantadas" como Return_5d_forward, evitando que el modelo reciba una señal directa del resultado a predecir.
- Embargo por horizonte (H): dado que el target se define con horizontes a H días vista (H=1 o H=5), se evita que observaciones situadas al final del conjunto de entrenamiento dependan de precios ya pertenecientes al periodo posterior (test). Operativamente, una vez definido el corte temporal train/test, se excluyen las últimas H observaciones del bloque de entrenamiento (iloc[:-H]) antes del entrenamiento y, en el caso de LSTM, antes de la construcción de secuencias. Esta medida ayuda a reducir el solapamiento de información entre bloques temporales contiguos. (López de Prado, 2018)

Validación temporal estricta (sin barajado)

La validación de modelos en finanzas requiere un enfoque estrictamente temporal para evitar sobreajuste y fugas de información. En este trabajo se adopta una evaluación *out-of-sample* basada

en particionado cronológico, evitando el barajado (*shuffle*) y respetando la secuencia temporal de la serie. Se define un corte fijo para todos los modelos y escenarios:

- Train: fechas anteriores a 2022-01-01
- Test: fechas desde 2022-01-01 en adelante
  Este punto de corte permite evaluar el rendimiento en un tramo reciente del mercado, manteniendo un conjunto de prueba completamente fuera de muestra y comparable entre modelos y escenarios.

Nota de comparabilidad por horizonte (efecto del embargo)

El embargo se define igual al horizonte de predicción (H=1 o H=5). Por ello, el conjunto de entrenamiento en 5d termina 4 sesiones antes que en 1d. Esta diferencia es esperable y responde a un control explícito de fuga temporal; la comparativa 'con vs. sin sentimiento' se realiza siempre dentro de cada horizonte, manteniendo idénticos los índices/fechas de train/test entre BASE, SIMPLE y FULL.

Optimización restringida al entrenamiento y validación cruzada temporal

En los modelos de *machine learning*, la búsqueda de hiperparámetros se limita al escenario BASE y se realiza únicamente dentro del conjunto de entrenamiento mediante validación cruzada temporal (TimeSeriesSplit), respetando el orden cronológico. Para reducir la cercanía entre pliegues contiguos, se utiliza una separación temporal (gap) coherente con el horizonte (gap = H) (López de Prado, 2018; Pedregosa et al., 2011)

En los escenarios SIMPLE y FULL se reutilizan las configuraciones para aislar el efecto del sentimiento y evitar que cambios de ajuste se confundan con el aporte de nuevas variables.

Preprocesado sin fuga de información

- Estandarización sin leakage: cuando se aplica StandardScaler, se ajusta exclusivamente con el train y se aplica posteriormente a validación/test, evitando que estadísticas del periodo out-of-sample influyan en el entrenamiento.
- Escalado dentro de *Pipeline* (ML): en los modelos que lo requieren (p. ej., Regresión Logística), el escalado se integra en un *Pipeline*, lo que asegura que en validación temporal el escalador se ajusta solo con el bloque correspondiente de cada split.(Pedregosa et al., 2011).

Gestión de días sin noticias (consistencia temporal tras el merge)

Dado que el calendario de mercado y el flujo de titulares no siempre están sincronizados, pueden existir sesiones sin noticias asociadas. Tal y como adelantamos anteriormente , para no perder observaciones válidas y permitir que el modelo aprenda el efecto de "no hay noticias", se incorpora tratamiento explícito:

- Indicador de disponibilidad: has_news (1 si existe información textual ese día, 0 si no).
- Imputación neutral y recuentos: variables como sentiment_filled y n_news_filled imputan a 0 los valores ausentes (neutralidad y ausencia de titulares), manteniendo la continuidad temporal sin introducir información futura. En el escenario FULL, el mismo criterio se aplica al resto de métricas extendidas cuando no hay titulares.

Reproducibilidad y trazabilidad de experimentos

- Control de aleatoriedad: se fijan semillas (Python/NumPy) y random_state en modelos estocásticos (p. ej., Random Forest), reduciendo variabilidad entre ejecuciones. En redes neuronales puede persistir variabilidad residual del *framework*; se mitiga con validación consistente y restauración de mejores pesos mediante early stopping.
- Uso de la misma configuración en escenarios con sentimiento: para que las diferencias de rendimiento dependan del conjunto de variables y no de cambios en el ajuste, los mejores hiperparámetros encontrados en BASE se guardan por horizonte y se reutilizan sin nuevo ajuste en SIMPLE y FULL.
- Persistencia de salidas: se guardan de forma sistemática métricas y predicciones (CSV/JSON), lo que facilita la revisión y comparación entre modelos, horizontes y escenarios.

f. Métricas de evaluación

La evaluación se aborda como un problema de clasificación binaria, en el que se predice si el índice sube o baja. Para analizar el rendimiento no se utiliza una única métrica, sino varias medidas que permiten valorar el acierto global, el comportamiento ante posibles desbalances entre clases y la capacidad del modelo para diferenciar entre subidas y bajadas a partir de las probabilidades estimadas. Todas las métricas se calculan sobre el periodo de evaluación. En las métricas que dependen de un umbral se utiliza el valor habitual de 0.5, mientras que ROC-AUC se calcula de forma independiente del umbral.

- Accuracy (exactitud): indica la proporción de predicciones correctas sobre el total. Es una medida sencilla de interpretar, aunque por sí sola puede ser poco informativa cuando las clases no están equilibradas.
- Balanced Accuracy: recoge el rendimiento medio en ambas clases, al considerar por igual la capacidad de acierto en subidas y en bajadas. Por ello, resulta más adecuada cuando existe cierto desbalance.
- Precision y Recall: Precision muestra qué parte de las predicciones positivas realizadas por el modelo corresponde realmente a casos positivos. Recall, o sensibilidad, indica qué parte de los positivos reales es detectada correctamente. Consideradas de forma conjunta, ayudan a entender mejor si el modelo tiende a generar más falsos positivos o más falsos negativos.
- F1-score: resume el equilibrio entre precision y recall en una sola medida, por lo que resulta útil cuando interesa valorar ambas al mismo tiempo.
- ROC-AUC: mide la capacidad del modelo para distinguir entre clases a partir de las probabilidades predichas, sin depender de un umbral fijo. Por ello, permite valorar la capacidad discriminativa del modelo aunque la clasificación final cambie según el punto de corte elegido. Además, en el escenario BASE se emplea como métrica principal en la optimización de hiperparámetros mediante GridSearchCV.
- Matriz de confusión: se utiliza para desglosar verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, lo que facilita una interpretación más detallada del tipo de errores que comete el clasificador.

En conjunto, estas métricas permiten obtener una visión más completa del rendimiento de cada modelo, ya que no solo recogen el porcentaje global de aciertos, sino también el equilibrio entre clases, el tipo de errores cometidos y la capacidad discriminativa basada en probabilidades.

5. Resultados

a. Set de evaluación

El periodo de evaluación (*test*) se define como el tramo final de la serie, desde 2022-01-03 hasta 2024-03-04 (n = 544). Este bloque se mantiene igual en todas las comparativas (tanto en modelos ML como en LSTM) y para ambos horizontes (1d y 5d), de forma que todos los resultados se midan en un marco común.

En el caso de las LSTM, el entrenamiento se realiza con un esquema *hold-out* temporal, separando un tramo de entrenamiento (2013-01-02 a 2020-03-13, n = 1812) y otro de validación (2020-03-17 a 2021-12-30, n = 453). Este bloque de validación se utiliza para monitorizar el entrenamiento y aplicar *early stopping*, seleccionando el punto de parada. En los modelos de ML no se fija un bloque de validación único; cuando procede, la selección de hiperparámetros se hace mediante validación temporal interna (TimeSeriesSplit) dentro del propio tramo de entrenamiento. La ligera diferencia en el corte del entrenamiento entre horizontes, debida al desplazamiento del target y al embargo, se explica en el apartado de Métodos.

Respecto al balance de clases, se observa un desbalance moderado hacia la clase positiva. En 1d, el porcentaje de positivos es 55.3% en *train* y 49.4% en *test*; en 5d, es 62.2% en *train* y 55.7% en *test*. Las métricas dependientes de umbral se calcularon con un umbral fijo de 0.5, mientras que ROC-AUC se mantuvo como referencia principal por su independencia del umbral.

Nota: en LSTM, el uso de ventanas (*lookback*) reduce el número efectivo de predicciones en *test* (por ejemplo, con *lookback* = 10, n = 535), por lo que las métricas se calculan sobre ese subconjunto.

b. Comparación principal: rendimiento con evaluación controlada

A partir del conjunto completo de experimentos recogidos en el Anexo III (Tabla 8.9), para esta comparativa principal se selecciona un único modelo por familia (ML y LSTM) y por horizonte (1d y 5d). La elección se realiza en el escenario BASE, tomando el modelo con mejor ROC-AUC dentro de cada bloque, por ser una métrica menos dependiente del umbral y útil para comparar la capacidad de discriminación. A partir de ahí, se mantiene fijo el modelo y el protocolo de entrenamiento y se evalúa su comportamiento en BASE, SIMPLE y FULL, de modo que la comparación entre escenarios dependa del conjunto de variables utilizado. En concreto, para 1d se utilizan Random Forest en ML y LSTM_64 en DL, mientras que para 5d se emplean Logistic Regression en ML y LSTM_32 en DL.

La Tabla 5-1 resume el rendimiento para cada horizonte y familia de modelos en los tres escenarios. Se presenta un panel con varias métricas (Accuracy, Balanced Accuracy, Precision, Recall, F1 y ROC-AUC), prestando especial atención a ROC-AUC y a Balanced Accuracy (más adecuada cuando hay un desbalance moderado de clases).

Tabla 5-1. Métricas obtenidas para cada horizonte y familia de los modelos. Fuente: elaboración propia.

Horizonte	Familia	Sentimiento	Modelo	Acc	B_Acc	Precision	Recall	F1	ROC_AUC
1d	ML	BASE	Random_Forest	0.513	0.515	0.506	0.677	0.579	**0.519**
1d	ML	SIMPLE	Random_Forest	0.5	0.502	0.496	0.714	0.585	**0.514**
1d	ML	FULL	Random_Forest	0.5	0.501	0.496	0.625	0.553	**0.508**

1d	DL	BASE	LSTM_64	0.493	0.495	0.495	0.846	0.624	**0.488**
1d	DL	SIMPLE	LSTM_64	0.553	0.554	0.536	0.752	0.626	**0.55**
1d	DL	FULL	LSTM_64	0.54	0.542	0.523	0.857	0.65	**0.55**
5d	ML	BASE	Logistic_Reg	0.528	0.522	0.576	0.574	0.575	**0.52**
5d	ML	SIMPLE	Logistic_Reg	0.568	0.527	0.573	0.884	0.695	**0.566**
5d	ML	FULL	Logistic_Reg	0.566	0.526	0.572	0.881	0.694	**0.557**
5d	DL	BASE	LSTM_32	0.564	0.5	0.564	1.0	0.722	**0.509**
5d	DL	SIMPLE	LSTM_32	0.551	0.494	0.561	0.94	0.703	**0.542**
5d	DL	FULL	LSTM_32	0.564	0.5	0.564	1.0	0.722	**0.538**

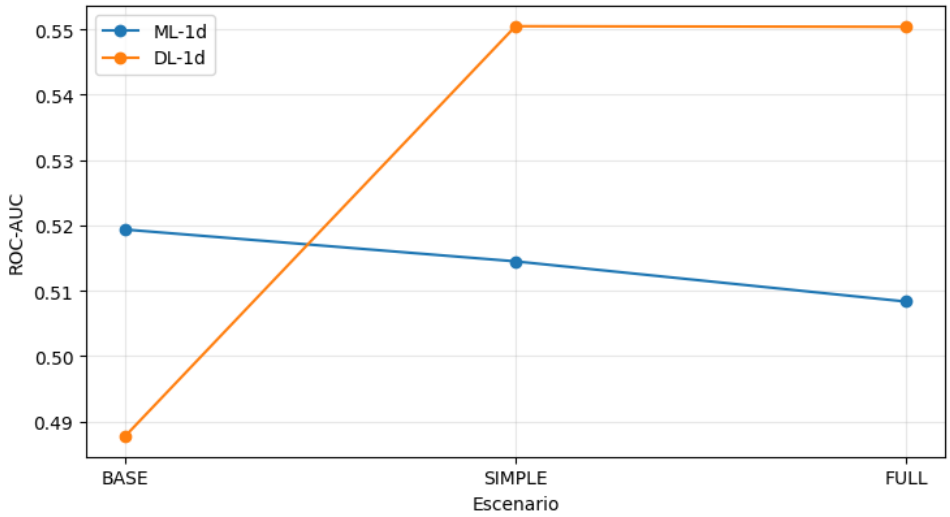

Figura 1. Evolución de ROC-AUC por escenario (BASE, SIMPLE, FULL) para ML y LSTM en horizonte 1d. Fuente: Elaboración propia.

En el horizonte 1d, los modelos de ML no muestran una mejora clara al añadir sentimiento: en SIMPLE y FULL los valores de ROC-AUC y Balanced Accuracy son muy parecidos a BASE, e incluso en algunos casos algo peores. Aunque en SIMPLE el F1 sube ligeramente, el resultado general apunta a que, para esta familia de modelos, el sentimiento no está aportando una ganancia consistente en capacidad de discriminación en predicción diaria. En cambio, en los modelos LSTM sí se aprecia una mejora al incorporar sentimiento, con aumentos en ROC-AUC, Balanced Accuracy y F1. Esto sugiere que una arquitectura secuencial puede aprovechar mejor la información textual agregada.

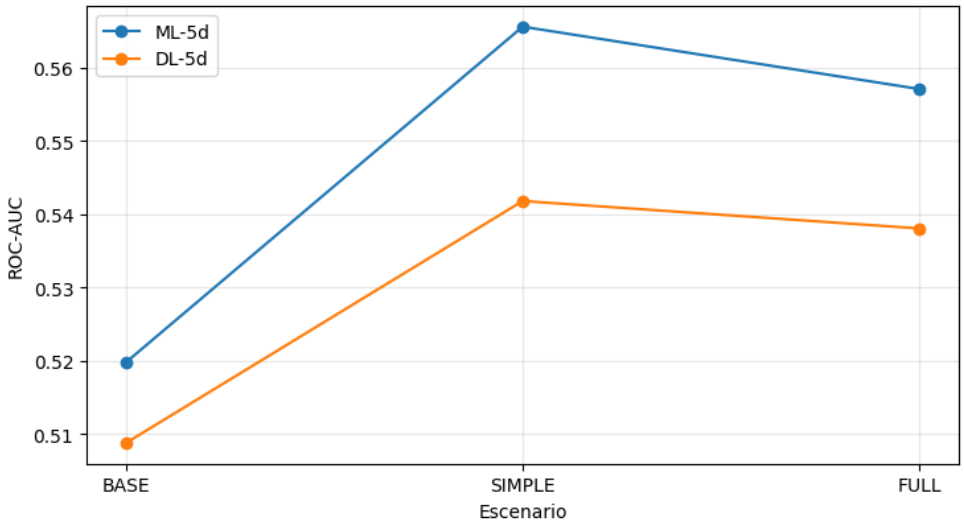

Figura 2. Evolución de ROC-AUC por escenario (BASE, SIMPLE, FULL) para ML y LSTM en horizonte 5d. Fuente: Elaboración propia.

En el horizonte 5d, los modelos de ML mejoran de forma más visible cuando se incluye sentimiento, sobre todo en el escenario SIMPLE, donde suben ROC-AUC y F1. Este patrón encaja con la idea de que, al ampliar el horizonte, la señal asociada a noticias puede tener un efecto más persistente y apreciable. En LSTM-5d, añadir sentimiento aumenta ROC-AUC, pero las métricas que dependen del umbral (por ejemplo, Balanced Accuracy) no mejoran en la misma proporción. Además, en algunos casos se observa un comportamiento muy extremo (recall cercano a 1.0), lo que indica que el modelo tiende a predecir casi siempre la clase positiva. Esto apunta a sensibilidad al umbral de decisión y/o a problemas de calibración de probabilidades.

En conjunto, esta comparación controlada indica que el efecto del sentimiento depende tanto del horizonte como del tipo de modelo: su aportación es más evidente en ML-5d y en LSTM-1d, mientras que en ML-1d el beneficio parece limitado.

Síntesis del bloque:

- El efecto del sentimiento no es uniforme: cambia según el horizonte y la familia de modelos.
- En esta comparación, el sentimiento se aprecia sobre todo en ML-5d y en LSTM-1d.
- En algunos casos mejora ROC-AUC pero no se refleja por igual en métricas como Balanced Accuracy o F1 con umbral fijo, lo que sugiere sensibilidad al umbral y/o a la calibración.

c. Ganancia incremental del sentimiento (Δ)

Para analizar con más detalle la aportación del sentimiento, se calcula cómo varía el rendimiento al pasar de BASE a SIMPLE y FULL. Igual que en el apartado anterior, la comparación se hace manteniendo el mismo modelo de referencia elegido en BASE para cada bloque (Horizonte × Familia), tal como se resume en la Tabla 5-2.

i. Cálculo de Δ.

Se reportan los incrementos Δ = métrica(escenario con sentimiento) − métrica(BASE) para ROC-AUC, Balanced Accuracy y F1. Se toma ROC-AUC como referencia principal por ser independiente del umbral, mientras que Balanced Accuracy y F1 aportan una visión complementaria del rendimiento una vez fijado el umbral de clasificación.

Tabla 5-2. Deltas (SIMPLE–BASE y FULL–BASE). Fuente: Elaboración propia.

Horizonte	Familia	Δ ROC_AUC SIMPLE-BASE	ΔROC_AUC FULL-BASE	Δ B_Acc SIMPLE-BASE	Δ B_Acc FULL-BASE	Δ F1 SIMPLE-BASE	Δ F1 FULL-BASE
1d	ML	-0.005	-0.011	-0.013	-0.014	0.006	-0.026
1d	DL	0.062	0.062	0.059	0.047	0.002	0.026
5d	ML	0.046	0.037	0.005	0.004	0.120	0.119
5d	DL	0.033	0.029	-0.006	0.000	-0.019	0.000

ii. Resultados: horizonte 1d

En ML-1d, añadir sentimiento no supone una ganancia: el cambio en ROC-AUC es ligeramente negativo (Δ ROC-AUC = −0.005 en SIMPLE y −0.011 en FULL). Esto viene acompañado de pequeñas caídas en Balanced Accuracy (−0.013 y −0.014) y sin una mejora estable en F1 (SIMPLE +0.006; FULL −0.026). En conjunto, estos resultados apuntan a que, con este protocolo y manteniendo fijo el modelo, el sentimiento no aporta una señal incremental robusta para la predicción diaria dentro de la familia ML.

En cambio, en DL-1d (LSTM) aparece la mejora más marcada de todo el estudio: Δ ROC-AUC = +0.062 tanto en SIMPLE como en FULL, junto con un incremento claro en Balanced Accuracy (+0.059 en SIMPLE; +0.047 en FULL) y mejoras pequeñas pero positivas en F1 (+0.002 y +0.026). Este patrón sugiere que el sentimiento sí añade información útil en 1d cuando se utiliza una arquitectura secuencial, posiblemente porque la LSTM es más capaz de captar relaciones temporales y no lineales asociadas a la señal textual agregada.

iii. Resultados: horizonte 5d

En ML-5d, el sentimiento aporta una mejora consistente: Δ ROC-AUC = +0.046 en SIMPLE y +0.037 en FULL, con incrementos modestos en Balanced Accuracy (+0.005; +0.004) y una subida notable de F1 (+0.120; +0.119). Esto encaja con la idea de que, al ampliar el horizonte, parte del ruido del corto plazo se reduce y la señal asociada a noticias puede reflejarse de forma más persistente, lo que facilita que modelos tabulares la aprovechen.

En DL-5d (LSTM), el sentimiento mejora ROC-AUC de forma moderada (+0.033 en SIMPLE; +0.029 en FULL), pero esa mejora no se refleja de manera equivalente en Balanced Accuracy (SIMPLE −0.006; FULL 0.000) ni en F1 (SIMPLE −0.019; FULL 0.000). Este desacople sugiere que la ganancia se nota más en el ordenamiento de probabilidades (ROC-AUC) que en la clasificación binaria con umbral 0.5. Por tanto, aquí la calibración de probabilidades y/o el ajuste del umbral podrían ser claves si se quisiera explotar mejor la señal en este bloque.

iv. SIMPLE vs FULL.

En general, FULL no mejora de forma sistemática a SIMPLE. Por ejemplo, en ML-5d SIMPLE obtiene el mayor Δ ROC-AUC (+0.046 frente a +0.037), y en DL-5d también queda ligeramente por encima (+0.033 vs +0.029). En DL-1d, ambos escenarios son prácticamente equivalentes en ROC-AUC (+0.062). Este patrón sugiere que añadir más variables de sentimiento (FULL) no implica

necesariamente más capacidad predictiva y, en algunos casos, puede aportar ruido o información redundante frente a una versión más sencilla (SIMPLE).

En resumen, el análisis de deltas refuerza que el efecto del sentimiento depende del horizonte y del tipo de modelo: se aprecia con más claridad en DL-1d y en ML-5d, mientras que en ML-1d no se observa mejora y en DL-5d el aumento de ROC-AUC no se traslada de forma clara a métricas dependientes del umbral. Además, FULL no supera de manera regular a SIMPLE, lo que sugiere que una representación más sencilla del sentimiento puede ser suficiente dentro de este marco experimental.

d. Matrices de confusión y tipo de error

Después de revisar el rendimiento global (5.b) y el aporte incremental del sentimiento (5.c), en este apartado se examina con más detalle el tipo de errores que cometen los modelos, es decir, cuántas veces clasifican incorrectamente subidas y bajadas. Para ello, se presentan matrices de confusión comparando los escenarios BASE y SIMPLE dentro de cada bloque de horizonte y familia (Figuras 3 y 4). En concreto, para 1d se utilizan Random Forest en ML y LSTM_64 en DL, mientras que para 5d se emplean Logistic Regression en ML y LSTM_32 en DL.

i. Resultados: horizonte 1d

En el horizonte 1d se observa una tendencia general a predecir con bastante frecuencia la clase positiva (“subida”), lo que provoca un número elevado de falsos positivos, sobre todo en la familia ML. En el caso de Random Forest, al pasar de BASE a SIMPLE los verdaderos negativos bajan de 97 a 80, mientras que los falsos positivos aumentan de 178 a 195. Al mismo tiempo, los falsos negativos se reducen de 87 a 77 y los verdaderos positivos suben de 182 a 192. En conjunto, esto indica que el modelo detecta mejor las subidas, pero a costa de confundir más bajadas reales como si fueran subidas.

En DL, la comparación entre LSTM_64 BASE y LSTM_64 SIMPLE muestra un comportamiento diferente. En BASE, la matriz presenta TN = 39, FP = 230, FN = 41 y TP = 225, lo que refleja una clara inclinación hacia la predicción de subidas. En SIMPLE, la distribución resulta más equilibrada, con TN = 96, FP = 173, FN = 66 y TP = 200. Esto significa que disminuyen los falsos positivos y aumentan los verdaderos negativos, aunque también se dejan de detectar algunas subidas reales. En términos generales, en 1d el modelo secuencial muestra una matriz más compensada en SIMPLE que en BASE.

En resumen, en el horizonte 1d el error más frecuente consiste en clasificar bajadas como subidas. No obstante, este patrón no afecta igual a ambas familias: en ML el sesgo hacia la clase positiva sigue siendo notable, mientras que en DL se reduce de forma visible.

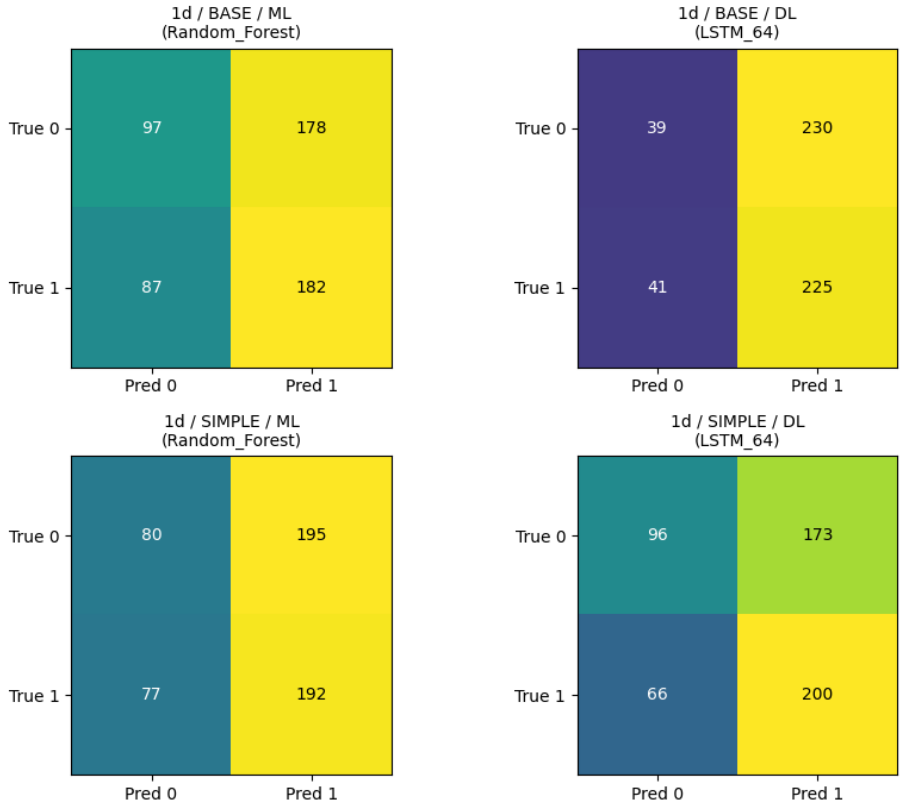

Figura 3. Matrices confusión. Horizonte 1d (BASE vs SIMPLE). Fuente: Elaboración propia.

ii. Resultados: horizonte 5d

En el horizonte 5d el comportamiento vuelve a diferenciarse claramente entre ML y DL. En ML, la comparación entre Logistic Regression BASE y Logistic Regression SIMPLE muestra que ambos escenarios conservan capacidad para separar las dos clases, aunque en SIMPLE el modelo se inclina más hacia la predicción de subidas. En BASE, la matriz es TN = 113, FP = 128, FN = 129 y TP = 174; en SIMPLE pasa a TN = 41, FP = 200, FN = 35 y TP = 268. Esto indica que el modelo acierta muchas más subidas y reduce bastante los falsos negativos, pero a cambio incrementa los falsos positivos y pierde capacidad para reconocer bajadas.

En DL, la comparación entre LSTM_32 BASE y LSTM_32 SIMPLE muestra un sesgo mucho más fuerte hacia la clase positiva. En BASE, la matriz es extrema: TN = 0, FP = 233, FN = 0 y TP = 302, es decir, todas las observaciones se clasifican como “subida”. En SIMPLE, la situación mejora ligeramente, con TN = 11, FP = 222, FN = 18 y TP = 284, pero el patrón general sigue siendo muy desequilibrado. Aunque aparecen algunos verdaderos negativos, la capacidad para identificar bajadas continúa siendo muy limitada.

Por tanto, en 5d la familia ML mantiene una discriminación más útil entre ambas clases, mientras que la familia DL sigue muy desplazada hacia la predicción de subidas, especialmente en el escenario BASE.

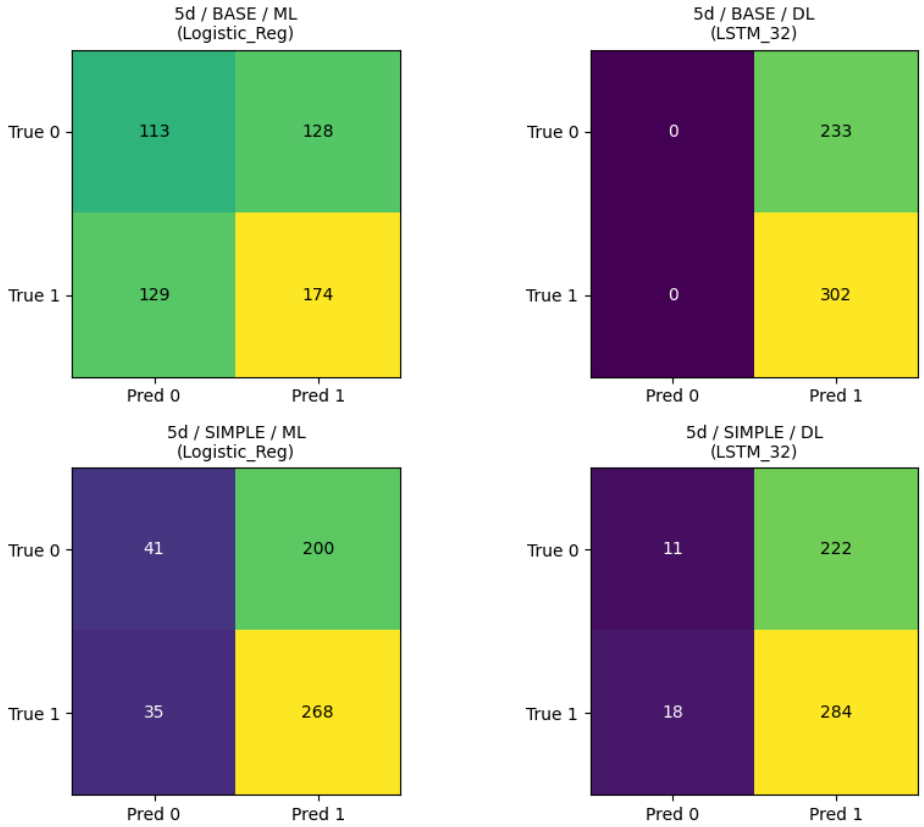

Figura 4. Matrices de confusión (Horizonte 5d, BASE vs SIMPLE). Fuente: Elaboración propia.

iii. Cierre

En conjunto, las matrices de confusión van en la misma línea que los apartados anteriores. En 1d aparece una tendencia general a predecir con mayor frecuencia la clase positiva, aunque este sesgo se reduce en DL al pasar de BASE a SIMPLE. En 5d, la diferencia entre familias es más clara: ML mantiene una capacidad más útil para distinguir entre subidas y bajadas, mientras que DL sigue muy concentrado en la clase positiva.

Estos resultados ayudan a entender por qué métricas como Balanced Accuracy y ROC-AUC son relevantes en este trabajo, ya que una accuracy simple puede resultar insuficiente cuando los errores se distribuyen de forma desequilibrada.

A continuación, se amplía la comparación observando de forma directa el comportamiento de ML frente a LSTM por horizonte y escenario.

e. Comparación ML vs LSTM por horizonte

En los apartados anteriores, la comparación se ha planteado de forma controlada para aislar el efecto del sentimiento. En este apartado, en cambio, se analiza el mejor resultado obtenido por cada familia de modelos (ML y DL/LSTM) dentro de cada escenario (BASE, SIMPLE y FULL). Para ello, se selecciona el mejor modelo de cada familia y escenario (Tabla 5-3) y después se comparan ambas familias mediante una tabla resumen (Tabla 5-4). El objetivo aquí no es medir de forma aislada el efecto del sentimiento, sino observar qué familia resulta más competitiva en cada configuración.

Tabla 5-3. Mejor modelo por (Horizonte × Familia × Escenario). Fuente: Elaboración propia.

Horizonte	Familia	Sentimiento	Modelo	Acc	B_Acc	Precision	Recall	F1	ROC_AUC
1d	ML	BASE	Random_Forest	0.513	0.515	0.506	0.677	0.579	0.519
1d	ML	SIMPLE	Hist_GB	0.506	0.509	0.5	0.784	0.611	0.524
1d	ML	FULL	Hist_GB	0.502	0.505	0.498	0.755	0.6	0.509
1d	DL	BASE	LSTM_64	0.493	0.495	0.495	0.846	0.624	0.488
1d	DL	SIMPLE	LSTM_64	0.553	0.554	0.536	0.752	0.626	0.55
1d	DL	FULL	LSTM_64	0.54	0.542	0.523	0.857	0.65	0.55
5d	ML	BASE	Logistic_Reg	0.528	0.522	0.576	0.574	0.575	0.52
5d	ML	SIMPLE	Logistic_Reg	0.568	0.527	0.573	0.884	0.695	0.566
5d	ML	FULL	Logistic_Reg	0.566	0.526	0.572	0.881	0.694	0.557
5d	DL	BASE	LSTM_32	0.564	0.5	0.564	1.0	0.722	0.509
5d	DL	SIMPLE	LSTM_64	0.563	0.498	0.564	0.997	0.72	0.547
5d	DL	FULL	LSTM_32	0.564	0.5	0.564	1.0	0.722	0.538

Tabla 5-4. Mejor ML vs mejor LSTM por (Horizonte × Escenario) con deltas ML−DL. Fuente elaboración propia.

H	Sent	Modelo ML	ROC AUC ML	B_Acc ML	F1 ML	Modelo DL	ROC AUC DL	B_Acc DL	F1 DL	Δ ROC_AUC ML-DL	Δ B_Acc ML-DL	Δ F1 ML-DL
1d	BASE	R_Forest	0.519	0.515	0.579	LSTM_64	0.488	0.495	0.624	0.031	0.02	-0.045
1d	SIMPLE	Hist_GB	0.524	0.509	0.611	LSTM_64	0.55	0.554	0.626	-0.026	-0.045	-0.015
1d	FULL	Hist_GB	0.509	0.505	0.6	LSTM_64	0.55	0.542	0.65	-0.041	-0.037	-0.05
5d	BASE	Logistic_Reg	0.52	0.522	0.575	LSTM_32	0.509	0.5	0.722	0.011	0.022	-0.147
5d	SIMPLE	Logistic_Reg	0.566	0.527	0.695	LSTM_64	0.547	0.498	0.72	0.019	0.029	-0.025
5d	FULL	Logistic_Reg	0.557	0.526	0.694	LSTM_32	0.538	0.5	0.722	0.019	0.026	-0.028

i. Resultados: horizonte 1d

En el escenario BASE, la familia ML rinde mejor que DL/LSTM tanto en capacidad de discriminación como en rendimiento balanceado, con una ventaja de ΔROC-AUC (ML−DL) = +0.031 y ΔB_Acc = +0.020. Sin embargo, cuando se incorpora sentimiento el patrón cambia: en SIMPLE y FULL, DL/LSTM pasa a superar a ML, con mejores valores en ROC-AUC (ΔROC-AUC ML−DL = −0.026 en SIMPLE y −0.041 en FULL) y también en balanced accuracy (ΔB_Acc = −0.045 y −0.037, respectivamente).

En cuanto a los “modelos ganadores” (Tabla 5.3), ML utiliza Random Forest en BASE y HistGradientBoosting en SIMPLE/FULL, mientras que DL mantiene LSTM_64 en los tres escenarios. En conjunto, para el horizonte 1d el sentimiento parece beneficiar de forma más clara a la arquitectura secuencial (LSTM), lo que encaja con lo observado en el apartado 5.c, donde el mayor delta por sentimiento aparecía precisamente en DL-1d.

ii. Resultados: horizonte 5d

En 5d, la familia ML obtiene mejores resultados que DL/LSTM en todos los escenarios, tanto en ROC-AUC como en balanced accuracy. Ya en BASE parte con ventaja (ΔROC-AUC ML−DL = +0.011; ΔB_Acc = +0.022) y esta se mantiene al añadir sentimiento: en SIMPLE y FULL, ML sigue por encima en ROC-AUC (ΔROC-AUC = +0.019 en ambos casos) y también en B_Acc (ΔB_Acc = +0.029 en SIMPLE y +0.026 en FULL).

A nivel de modelos ganadores (Tabla 5.3), ML selecciona regresión logística en los tres escenarios. En DL aparecen LSTM_32 en BASE y FULL y LSTM_64 en SIMPLE. Aunque DL muestre un F1 alto en 5d, ese resultado está muy influido por un sesgo fuerte hacia la clase positiva (recall cercano a 1.0), lo que reduce la capacidad para detectar bajadas y explica un rendimiento balanceado alrededor de 0.5 en esta familia para 5d.

iii. Cierre

En resumen, la comparación del mejor modelo por escenario también muestra un comportamiento distinto según el horizonte: en 1d, ML rinde mejor en BASE, pero LSTM pasa a situarse por encima cuando se incorpora sentimiento; en 5d, ML se mantiene por delante de forma consistente en ROC-AUC y Balanced Accuracy en los tres escenarios. Este resultado encaja con lo observado en el apartado 5.c, donde la mejora asociada al sentimiento se concentra en DL-1d y en ML-5d, mientras que DL-5d sigue mostrando limitaciones prácticas por su tendencia a predecir en exceso la clase positiva.

Aunque esta comparación del mejor modelo por escenario no tiene el mismo carácter controlado que la comparativa principal, sí mantiene una lectura compatible con ella. Por ello, se considera un análisis complementario que ayuda a reforzar los hallazgos ya observados.

6. Conclusiones

En este Trabajo Fin de Máster se ha estudiado si la incorporación de variables de sentimiento, obtenidas a partir de titulares financieros, puede mejorar la predicción de la dirección del S&P 500. Para ello, se planteó una comparación entre tres escenarios (BASE, SIMPLE y FULL), dos horizontes de predicción (1d y 5d) y dos familias de modelos (ML tabular y LSTM). El análisis se llevó a cabo siguiendo un enfoque temporal estricto y aplicando medidas para reducir sesgos y evitar fugas de información, con el fin de que las diferencias observadas entre escenarios pudieran interpretarse dentro del diseño experimental establecido.

a. Respuesta a la pregunta de investigación

A partir de los resultados obtenidos, puede concluirse que el sentimiento sí aporta información útil para la predicción, aunque su efecto no aparece de la misma forma en todos los casos. Su contribución depende tanto del horizonte de predicción como del tipo de modelo utilizado. En conjunto, el aporte del sentimiento se aprecia con más claridad en los modelos de ML para 5 días y en LSTM para 1 día. Sin embargo, en ML a 1 día no se observa una mejora suficientemente consistente, mientras que en LSTM a 5 días aparecen limitaciones prácticas relacionadas con una tendencia muy marcada a predecir la clase positiva.

b. Conclusiones por horizonte (1d vs 5d)

En el horizonte de 1 día, los modelos de ML no muestran una mejora estable al incorporar variables de sentimiento. Los cambios en ROC-AUC y Balanced Accuracy son muy pequeños e incluso en algunos casos ligeramente negativos, y las mejoras puntuales en F1 no van acompañadas de una ganancia clara en capacidad discriminativa. En cambio, en LSTM para 1 día sí se observa la mejora incremental más clara del estudio, tanto en ROC-AUC como en métricas relacionadas con el equilibrio entre clases. Esto sugiere que una arquitectura secuencial puede aprovechar mejor la señal textual agregada cuando se trabaja en un horizonte muy corto.

En el horizonte de 5 días el comportamiento es diferente. En este caso, los modelos tabulares de ML sí presentan una mejora más estable cuando se incorpora sentimiento, especialmente en el escenario SIMPLE, con aumentos apreciables en ROC-AUC y F1. Por su parte, en LSTM-5d la mejora en ROC-AUC es más moderada y no se refleja de forma equivalente en Balanced Accuracy. Además, en algunos experimentos aparece una inclinación excesiva hacia la clase positiva, con recall muy alto pero una especificidad muy baja, lo que reduce su utilidad si también interesa detectar correctamente los periodos de caída.

c. Conclusiones por familia de modelos (ML vs LSTM)

En los modelos de ML, el uso de variables de sentimiento ofrece resultados más sólidos en 5 días que en 1 día. De hecho, al comparar el mejor modelo de cada escenario, se aprecia una ventaja relativamente estable de ML frente a LSTM en ese horizonte. En cambio, en 1 día LSTM se vuelve más competitivo cuando se añaden variables de sentimiento.

Además, en LSTM el rendimiento parece depender más del horizonte y también del uso de un umbral fijo para convertir probabilidades en clases. El desacople observado en 5 días entre ROC-AUC y métricas como Balanced Accuracy o F1 sugiere que parte de la información útil sí está presente en las probabilidades generadas por el modelo, pero no termina de trasladarse con la misma claridad a la clasificación binaria cuando se utiliza el umbral 0.5.

d. Conclusiones sobre escenarios (BASE vs SIMPLE vs FULL)

Los resultados tampoco muestran que FULL supere de manera sistemática a SIMPLE. En aquellos casos en los que el sentimiento sí parece aportar valor, como ML-5d y LSTM-1d, el escenario FULL tiende a igualar o quedar ligeramente por debajo de SIMPLE en ROC-AUC. Esto sugiere que añadir un mayor número de variables de sentimiento no implica necesariamente una mejora del rendimiento. Dentro del marco de este trabajo, la versión SIMPLE parece suficiente para captar la mayor parte de la señal útil, y probablemente resulte una opción más robusta al reducir el riesgo de introducir ruido o redundancia.

e. Contraste de hipótesis

H1 (valor incremental del sentimiento) no se confirma en su totalidad. Solo parcialmente. Los resultados muestran una mejora clara en LSTM-1d y en ML-5d, pero no una mejora robusta en ML-1d. En LSTM-5d, aunque aparece cierta mejora en ROC-AUC, esta no se mantiene con la misma claridad en métricas dependientes del umbral.

H2 (dependencia del horizonte) queda respaldada por los resultados. El efecto del sentimiento cambia entre 1 día y 5 días, no solo en intensidad, sino también en el tipo de modelo que mejor lo aprovecha.

H3 (interacción con la familia de modelos) también encuentra apoyo en la evidencia obtenida. El sentimiento no afecta del mismo modo a los modelos tabulares y a LSTM: su contribución se observa con más claridad en LSTM para 1 día y en ML para 5 días, además de mostrar diferencias en estabilidad y en el tipo de errores cometidos.

f. Aportaciones del trabajo

Más allá de los resultados numéricos, la principal aportación de este trabajo está en el planteamiento metodológico. En concreto, se ha diseñado una comparación tipo *ablation* entre los escenarios BASE, SIMPLE y FULL, manteniendo la comparabilidad temporal y las mismas condiciones de evaluación. A esto se añaden varias medidas orientadas a controlar sesgos, como la partición cronológica fija, el embargo según horizonte, el uso de gap en la validación temporal, la exclusión de variables con riesgo de fuga de información y la reutilización de hiperparámetros en los escenarios con sentimiento. Además, el tratamiento de los días sin noticias mediante indicadores específicos e imputación neutral ha permitido integrar de forma coherente la información textual con las series de mercado.

g. Limitaciones

Este trabajo presenta varias limitaciones que conviene tener en cuenta al interpretar los resultados.

La primera tiene que ver con la fuente de noticias y la granularidad temporal. El corpus utilizado es estático y trabaja con agregación diaria, sin disponer de marcas temporales intradía. Esto puede ocultar reacciones que ocurren dentro de la misma sesión y mezclar noticias publicadas en momentos diferentes del día.

La segunda se relaciona con la representación textual. Se han utilizado titulares y un único modelo de sentimiento, FinBERT-tone, sin incorporar el cuerpo completo de las noticias, metadatos como la fuente o la relevancia, ni otras representaciones semánticas más ricas.

Otra limitación importante es la no estacionariedad propia de los mercados financieros. El comportamiento del mercado cambia con el tiempo y una única partición *train/test* no permite recoger toda esa variabilidad ni garantiza que los resultados se mantengan en otros periodos.

Por último, el trabajo se centra en un objetivo direccional, es decir, en la capacidad de clasificar subidas y bajadas. Esto permite evaluar valor predictivo, pero no equivale directamente a rentabilidad económica, ya que no se consideran costes de transacción, deslizamiento, gestión del riesgo ni una función objetivo de carácter financiero.

h. Líneas futuras

A partir de lo anterior, pueden plantearse varias líneas de trabajo futuras.

Una primera ampliación consistiría en utilizar un dataset de noticias financieras más completo, más homogéneo y continuo a lo largo de toda la serie temporal. Esto ayudaría a reducir los problemas de cobertura detectados en los primeros años, limitar la necesidad de imputación neutral y analizar la contribución del texto en un marco temporal más consistente.

También sería interesante trabajar en la calibración de probabilidades y en la selección del umbral, especialmente en aquellos casos en los que ROC-AUC mejora pero Balanced Accuracy y F1 no lo hacen en la misma medida, como ocurre de forma clara en LSTM-5d.

Otra posible extensión sería realizar una evaluación *rolling* o *walk-forward*, con reentrenamiento periódico y ventanas temporales móviles, para recoger mejor la no estacionariedad y acercar el experimento a un uso más realista.

Además, la señal textual podría enriquecerse incorporando el cuerpo de las noticias, entidades o temas, medidas de sorpresa informativa y comparaciones con otros modelos.

En la misma línea, una mejor alineación temporal entre noticias y mercado, mediante *timestamps* intradía o estrategias que reduzcan la ambigüedad sobre la disponibilidad real de la información, permitiría afinar el diseño experimental.

Por último, sería útil extender la comparación a nuevas arquitecturas y posibles ensambles, por ejemplo combinaciones entre modelos tabulares y secuenciales, siempre manteniendo el mismo protocolo de control de sesgos para asegurar comparaciones justas.

7. Referencias bibliográficas (APA)

Araci, D. (2019). *FinBERT: Financial sentiment analysis with pre-trained language models.* Recuperado el 15 de enero de 2026, de https://arxiv.org/abs/1908.10063

Aroussi, R. (2026). *yfinance* (versión 1.1.0). Recuperado el 15 de enero de 2026, de https://pypi.org/project/yfinance/

Dasmahaptra, D. (s. f.). *S&P 500 with financial news headlines (2008–2024).* Recuperado el 15 de enero de 2026, de https://www.kaggle.com/datasets/dyutidasmahaptra/s-and-p-500-with-financial-news-headlines-20082024

Devlin, J., Chang, M.-W., Lee, K. y Toutanova, K. (2019). *BERT: Pre-training of deep bidirectional transformers for language understanding*. Recuperado el 15 de enero de 2026, de https://aclanthology.org/N19-1423/

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417.

Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.

Huang, A. H., Wang, H. y Yang, Y. (2023). FinBERT: A large language model for extracting information from financial text. *Contemporary Accounting Research*, 40(2), 806-841.

Lo, A. W. (2004). The Adaptive Markets Hypothesis: Market efficiency from an evolutionary perspective. *The Journal of Portfolio Management*, 30(5), 15-29.

López de Prado, M. (2018). *Advances in financial machine learning*. Hoboken, New Jersey: Wiley.

Loughran, T. y McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35-65.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O. y otros (2011). Scikit-learn: *Machine learning* in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A. y otros (2020). Transformers: State-of-the-art natural language processing. Recuperado el 15 de enero de 2026, de https://aclanthology.org/2020.emnlp-demos.6/

Yahoo Finance. (s. f.). *S&P 500 (^GSPC).* Recuperado el 15 de enero de 2026, de https://finance.yahoo.com/quote/%5EGSPC/

yiyanghkust. (s. f.). *finbert-tone (yiyanghkust/finbert-tone*). Recuperado el 15 de enero de 2026, de https://huggingface.co/yiyanghkust/finbert-tone

8. ANEXOS

ANEXO I. Detalle de arquitecturas e hiperparámetros

Modelos de *Machine Learning* (ML): Hiperparámetros finales

Tabla 8-1 Hiperparámetros finales por modelo y horizonte (ML). Fuente: Elaboración propia

Modelo	Hiperparámetros fijos	1d (final)	5d (final)
Dummy Classifier	strategy="most_frequent"	—	—
Regresión Logística	max_iter=1000; class_weight="balanced"; StandardScaler en *Pipeline*	C=0.01; solver="liblinear"	C=0.01; solver="liblinear"
Random Forest	max_features="sqrt"; class_weight="balanced"; n_jobs=-1; random_state=42	n_estimators=300; max_depth=10; min_samples_leaf=20	n_estimators=300; max_depth=3; min_samples_leaf=50
HistGradient Boosting Classifier	random_state=42	learning_rate=0.1; max_depth=3; min_samples_leaf=50	learning_rate=0.1; max_depth=10; min_samples_leaf=50

Tabla 8-2. Hiperparámetros y configuración de entrenamiento (LSTM) Fuente: Elaboración propia

Bloque	Parámetro	Valor
Datos (secuencias)	lookback	10
	input shape	(n_muestras, 10, n_features)
Modelo	unidades LSTM	32 / 64 (variantes evaluadas)
	regularización	L2 = 1e-4 (en LSTM y Dense)
	dropout	0.2 (tras LSTM y tras Dense)
	activaciones	Dense oculta: ReLU; salida: Sigmoid
Optimización	optimizador	Adam
	learning rate	1e-3
	loss	binary_crossentropy
	métricas	accuracy; ROC-AUC
Entrenamiento	epochs	100

	batch_size	32
Callbacks	EarlyStopping	monitor=val_roc_auc; mode=max; patience=10; restore_best_weights=True
	ReduceLROnPlateau	monitor=val_roc_auc; factor=0.5; patience=5; min_lr=1e-5

ANEXO II. Diccionario de Variables (Features)

Tabla 8-3. Variables presentes en el dataset (no usadas como predictores). Fuente: Elaboración propia

Variable	Tipo	Descripción
Date	Fecha	Fecha de la sesión bursátil (índice temporal)
Open	Numérica	Precio de apertura diario
High	Numérica	Máximo diario
Low	Numérica	Mínimo diario
Close	Numérica	Precio de cierre diario
Volume	Numérica	Volumen diario negociado

Tabla 8-4. Variables técnicas (predictores en BASE/SIMPLE/FULL). Fuente: Elaboración propia

Variable	Definición	Cálculo
Return	Retorno simple diario	Return = Close.pct_change() = (C_t/C_{t-1}) - 1
ret_lag_1	Retorno rezagado 1 día	ret_lag_1 = Return.shift(1)
ret_lag_2	Retorno rezagado 2 días	ret_lag_2 = Return.shift(2)
ret_lag_3	Retorno rezagado 3 días	ret_lag_3 = Return.shift(3)
ret_lag_4	Retorno rezagado 4 días	ret_lag_4 = Return.shift(4)
ret_lag_5	Retorno rezagado 5 días	ret_lag_5 = Return.shift(5)
ret_ma_5	Media móvil de retornos (5)	ret_ma_5 = mean(Return_{t-4..t})
ret_std_5	Volatilidad móvil (5)	ret_std_5 = std(Return_{t-4..t})
ret_ma_10	Media móvil de retornos (10)	ret_ma_10 = mean(Return_{t-9..t})
ret_std_10	Volatilidad móvil (10)	ret_std_10 = std(Return_{t-9..t})

Tabla 8-5. Variables de sentimiento (SIMPLE). Fuente: Elaboración propia

Variable	Definición	Cálculo	Nota práctica
sentiment_mean	Media diaria del sentimiento firmado	mean(sentiment_signed) por día	Puede ser NaN si no hay noticias
n_news	Número de noticias del día	count(titulares del día)	Puede ser NaN si no hay noticias
has_news	Indicador de noticias	1 si n_news>0; si no 0	Siempre 0/1

sentiment_filled	Sentimiento imputado para modelado	sentiment_mean si has_news=1; si no 0	Evita NaN en ML/DL
n_news_filled	Conteo imputado para modelado	n_news si has_news=1; si no 0	Evita NaN en ML/DL

Tabla 8-6. Variables de sentimiento adicionales Fuente: Elaboración propia

Variable	Definición	Cálculo	Nota práctica
sentiment_median	Mediana diaria del sentimiento firmado	median(sentiment_signed) por día	Si no hay noticias se imputa a 0
sentiment_std	Dispersión diaria del sentimiento firmado	std(sentiment_signed) por día	Si n<2 o sin noticias se imputa a 0
pos_ratio	Proporción de titulares positivos	#positivos / n_news	Si no hay noticias se imputa a 0
neg_ratio	Proporción de titulares negativos	#negativos / n_news	Si no hay noticias se imputa a 0
neu_ratio	Proporción de titulares neutros	#neutros / n_news	Si no hay noticias se imputa a 0

Tabla 8-7. Variables objetivo y auxiliares (no features). Fuente: Elaboración propia

Variable	Definición	Cálculo
Target_1d	Dirección futura a 1 día (0/1)	(Return.shift(-1) > 0).astype(int)
Return_5d_forward	Retorno futuro a 5 días	Close.shift(-5)/Close - 1
Target_5d	Dirección futura a 5 días (0/1)	(Return_5d_forward > 0).astype(int)

Tabla 8-8. Disponibilidad por escenario (BASE / SIMPLE / FULL). Fuente: Elaboración propia

Variable	BASE	SIMPLE	FULL
Return	Sí	Sí	Sí
ret_lag_1..ret_lag_5	Sí	Sí	Sí
ret_ma_5; ret_std_5	Sí	Sí	Sí
ret_ma_10; ret_std_10	Sí	Sí	Sí
sentiment_mean	No	Sí	Sí
n_news	No	Sí	Sí
has_news	No	Sí	Sí
sentiment_filled	No	Sí	Sí

n_news_filled	No	Sí	Sí
sentiment_median	No	No	Sí
sentiment_std	No	No	Sí
pos_ratio	No	No	Sí
neg_ratio	No	No	Sí
neu_ratio	No	No	Sí

ANEXO III. Resultados extendidos (Tablas completas)

Tabla completa de métricas por experimento (TEST)

Tabla 8-9. Resultado completo métricas por experimento. Fuente: Elaboración propia

Horizonte	Sentimiento	Familia	Modelo	Acc	B_Acc	Precision	Recall	F1	ROC_AUC
1d	BASE	ML	Dummy_MostFreq	0.494	0.5	0.494	1.0	0.662	0.5
1d	BASE	ML	Hist_GB	0.491	0.494	0.49	0.766	0.598	0.51
1d	BASE	ML	Logistic_Reg	0.483	0.484	0.479	0.513	0.496	0.482
1d	BASE	ML	Random_Forest	0.513	0.515	0.506	0.677	0.579	0.519
1d	BASE	DL	LSTM_32	0.479	0.481	0.486	0.842	0.616	0.465
1d	BASE	DL	LSTM_64	0.493	0.495	0.495	0.846	0.624	0.488
1d	SIMPLE	ML	Dummy_MostFreq	0.494	0.5	0.494	1.0	0.662	0.5
1d	SIMPLE	ML	Hist_GB	0.506	0.509	0.5	0.784	0.611	0.524
1d	SIMPLE	ML	Logistic_Reg	0.487	0.486	0.478	0.409	0.441	0.48
1d	SIMPLE	ML	Random_Forest	0.5	0.502	0.496	0.714	0.585	0.514
1d	SIMPLE	DL	LSTM_32	0.507	0.509	0.502	0.985	0.665	0.507
1d	SIMPLE	DL	LSTM_64	0.553	0.554	0.536	0.752	0.626	0.55
1d	FULL	ML	Dummy_MostFreq	0.494	0.5	0.494	1.0	0.662	0.5
1d	FULL	ML	Hist_GB	0.502	0.505	0.498	0.755	0.6	0.509
1d	FULL	ML	Logistic_Reg	0.476	0.475	0.467	0.416	0.44	0.481
1d	FULL	ML	Random_Forest	0.5	0.501	0.496	0.625	0.553	0.508
1d	FULL	DL	LSTM_32	0.531	0.533	0.517	0.835	0.639	0.548
1d	FULL	DL	LSTM_64	0.54	0.542	0.523	0.857	0.65	0.55
5d	BASE	ML	Dummy_MostFreq	0.557	0.5	0.557	1.0	0.715	0.5
5d	BASE	ML	Hist_GB	0.546	0.508	0.561	0.845	0.675	0.508
5d	BASE	ML	Logistic_Reg	0.528	0.522	0.576	0.574	0.575	0.52
5d	BASE	ML	Random_Forest	0.517	0.473	0.542	0.855	0.663	0.464
5d	BASE	DL	LSTM_32	0.564	0.5	0.564	1.0	0.722	0.509
5d	BASE	DL	LSTM_64	0.564	0.5	0.564	1.0	0.722	0.504
5d	SIMPLE	ML	Dummy_MostFreq	0.557	0.5	0.557	1.0	0.715	0.5
5d	SIMPLE	ML	Hist_GB	0.546	0.501	0.557	0.898	0.688	0.507
5d	SIMPLE	ML	Logistic_Reg	0.568	0.527	0.573	0.884	0.695	0.566
5d	SIMPLE	ML	Random_Forest	0.522	0.475	0.543	0.888	0.674	0.457
5d	SIMPLE	DL	LSTM_32	0.551	0.494	0.561	0.94	0.703	0.542

5d	SIMPLE	DL	LSTM_64	0.563	0.498	0.564	0.997	0.72	0.547
5d	FULL	ML	Dummy_MostFreq	0.557	0.5	0.557	1.0	0.715	0.5
5d	FULL	ML	Hist_GB	0.529	0.485	0.549	0.875	0.674	0.469
5d	FULL	ML	Logistic_Reg	0.566	0.526	0.572	0.881	0.694	0.557
5d	FULL	ML	Random_Forest	0.529	0.481	0.547	0.908	0.682	0.463
5d	FULL	DL	LSTM_32	0.564	0.5	0.564	1.0	0.722	0.538
5d	FULL	DL	LSTM_64	0.564	0.5	0.564	1.0	0.722	0.532

Tabla 8-10. Matrices de confusión (TN/FP/FN/TP). Fuente: Elaboración propia.

Horizonte	Sentimiento	Familia	Modelo	tn	fp	fn	tp
1d	BASE	ML	Dummy_MostFreq	0	275	0	269
1d	BASE	ML	Logistic_Reg	125	150	131	138
1d	BASE	ML	Random_Forest	97	178	87	182
1d	BASE	ML	Hist_GB	61	214	63	206
1d	BASE	DL	LSTM_32	32	237	42	224
1d	BASE	DL	LSTM_64	39	230	41	225
1d	SIMPLE	ML	Dummy_MostFreq	0	275	0	269
1d	SIMPLE	ML	Logistic_Reg	155	120	159	110
1d	SIMPLE	ML	Random_Forest	80	195	77	192
1d	SIMPLE	ML	Hist_GB	64	211	58	211
1d	SIMPLE	DL	LSTM_32	9	260	4	262
1d	SIMPLE	DL	LSTM_64	96	173	66	200
1d	FULL	ML	Dummy_MostFreq	0	275	0	269
1d	FULL	ML	Logistic_Reg	147	128	157	112
1d	FULL	ML	Random_Forest	104	171	101	168
1d	FULL	ML	Hist_GB	70	205	66	203
1d	FULL	DL	LSTM_32	62	207	44	222
1d	FULL	DL	LSTM_64	61	208	38	228
5d	BASE	ML	Dummy_MostFreq	0	241	0	303
5d	BASE	ML	Logistic_Reg	113	128	129	174
5d	BASE	ML	Random_Forest	22	219	44	259
5d	BASE	ML	Hist_GB	41	200	47	256
5d	BASE	DL	LSTM_32	0	233	0	302
5d	BASE	DL	LSTM_64	0	233	0	302

5d	SIMPLE	ML	Dummy_MostFreq	0	241	0	303
5d	SIMPLE	ML	Logistic_Reg	41	200	35	268
5d	SIMPLE	ML	Random_Forest	15	226	34	269
5d	SIMPLE	ML	Hist_GB	25	216	31	272
5d	SIMPLE	DL	LSTM_32	11	222	18	284
5d	SIMPLE	DL	LSTM_64	0	233	1	301
5d	FULL	ML	Dummy_MostFreq	0	241	0	303
5d	FULL	ML	Logistic_Reg	41	200	36	267
5d	FULL	ML	Random_Forest	13	228	28	275
5d	FULL	ML	Hist_GB	23	218	38	265
5d	FULL	DL	LSTM_32	0	233	0	302
5d	FULL	DL	LSTM_64	0	233	0	302

ANEXO IV. Muestras de procesamiento NLP (FinBERT) y agregación diaria

Tabla 8-11. Ejemplos de sentimiento diario agregado (FULL). Fuente: Elaboración propia.

Date	n_news	sentiment_mean	sentiment_median	sentiment_std	pos_ratio	neg_ratio	neu_ratio
2020-08-03	6	0.830422	0.999984	0.406882	0.833333	0.000000	0.166667
2023-01-18	6	-0.650742	-0.955097	0.504774	0.000000	0.666667	0.333333
2018-10-03	5	0.000000	0.000000	0.000000	0.000000	0.000000	1.000000

Tabla 8-12. Titulares reales (muestra) de los días seleccionados. Fuente: Elaboración propia.

Date	Titular (muestra)
2020-08-03	S&P 500 Update: Where To Next? And What Then?
2020-08-03	Amid 22% Jump In Sales, Clorox Names Female CEO
2020-08-03	Big Tech's Big Beat
2020-08-03	Apple Stock Has Its Best July Since 2006
2023-01-18	Live updates: Stocks sink after retail sales fall, even as inflation slows significantly
2023-01-18	S&P 500 posts worst day in more than a month, Dow closes 600 points lower
2023-01-18	Stocks close lower on Thursday, Dow and S&P 500 notch third day of losses
2018-10-03	Market Diverges ... Is This a Signal?
2018-10-03	Barnes & Noble stock soars 20% as it explores a sale
2018-10-03	Why Stock Market's 'Out of Whack' Leadership Signals Next Crash

Estos ejemplos ilustran la transformación del corpus de noticias (titulares diarios) en variables numéricas agregadas por sesión (sentiment_mean, ratios y dispersión), que posteriormente se integran en los escenarios SIMPLE y FULL.

ANEXO V. Fuentes de datos

Tabla 8-13. Resumen de datasets utilizados. Fuente: Elaboración propia.

Dataset	Descripción	Fuente	Rango de fechas	Granula-ridad	Tamaño
sp500_model.csv	Serie S&P 500 + features técnicas (retornos/estadísticos móviles) + targets	Yahoo Finance (vía descarga programática)	2013-01-02 a 2024-03-04	Diaria (sesión)	2811 filas (2811 fechas)
sp500_sent_model.csv	BASE + sentimiento diario agregado SIMPLE (sentiment_mean, n_news, filled, has_news)	Derivado de sp500_model + FinBERT + agregación diaria	2013-01-02 a 2024-03-04	Diaria (sesión)	2811 filas (2811 fechas)
sp500_sent_FULL.csv	BASE + sentimiento diario agregado FULL (ratios, mediana, std, etc.)	Derivado de sp500_model + FinBERT + agregación diaria	2013-01-02 a 2024-03-04	Diaria (sesión)	2811 filas (2811 fechas)
sp500_news_kaggle.csv	Corpus de noticias (titulares) asociado al S&P 500	Kaggle (dataset de noticias financieras)	2008-01-02 a 2024-03-04	Por titular	19127 filas (19127 titulares; 3507 fechas únicas)
sentiment_daily.csv	Sentimiento diario agregado SIMPLE (por fecha)	Derivado del corpus + FinBERT + agregación diaria	2008-01-02 a 2024-03-04	Diaria (fecha)	3507 filas (3507 fechas)
sentiment_daily_FULL.csv	Sentimiento diario agregado FULL (ratios y dispersión)	Derivado del corpus + FinBERT + agregación diaria	2008-01-02 a 2024-03-04	Diaria (fecha)	3507 filas (3507 fechas)

ANEXO VI. Fragmentos de código críticos

Agregación diaria de sentimiento a partir de titulares clasificados con FinBERT:

```
df_news["sentiment_label"] = df_news["sentiment_label"].str.lower()


label_to_sign = {"positive": 1, "negative": -1, "neutral": 0}
df_news["sentiment_signed"] =
df_news["sentiment_label"].map(label_to_sign)*df_news["sentiment_sc
ore"]


df_news["day"] = df_news["Date"].dt.normalize()



daily_model = df_news.groupby("day").agg(
    sentiment_mean=("sentiment_signed", "mean"),
    n_news=("sentiment_signed", "count"),
).reset_index().rename(columns={"day":"Date"})


daily_full = df_news.groupby("day").agg(
    sentiment_mean=("sentiment_signed", "mean"),
    sentiment_median=("sentiment_signed", "median"),
    sentiment_std=("sentiment_signed", "std"),
    n_news=("sentiment_signed", "count"),
    pos_ratio=("sentiment_label", lambda x: (x ==
"positive").mean()),
    neg_ratio=("sentiment_label", lambda x: (x ==
"negative").mean()),
    neu_ratio=("sentiment_label", lambda x: (x ==
"neutral").mean()),
).reset_index().rename(columns={"day":"Date"})
```

Inferencia de sentimiento sobre titulares financieros mediante FinBERT en lotes:

```
def finbert_predict(texts, batch_size=32):
    out = []
    for i in tqdm(range(0, len(texts), batch_size)):
        batch = texts[i:i+batch_size]
```

```
        out.extend(finbert(list(batch)))
    return out

texts = df_news["text"].tolist()
pred = finbert_predict(texts, batch_size=32)

df_news["sentiment_label"] = [r["label"] for r in pred]
df_news["sentiment_score"] = [r["score"] for r in pred]
```

Split temporal con embargo (anti-leakage) en train/test (ML y LSTM):

```
H = 1 # (o H=5 según horizonte)
train_mask = df.index < "2022-01-01"

X_train_raw = X.loc[train_mask].iloc[:-H]
y_train = Y.loc[train_mask].iloc[:-H]

X_test_raw = X.loc[~train_mask]
y_test = Y.loc[~train_mask]
```

Validación temporal en ML con TimeSeriesSplit(gap=H) y ajuste mediante GridSearchCV (a modo de ejemplo con Logistic Regression):

```
tscv = TimeSeriesSplit(n_splits=5, gap=H)

pipe_lr = Pipeline(
    steps=[
        ("scaler", StandardScaler()),
        ("clf", LogisticRegression(max_iter=1000,
class_weight="balanced")),
    ]
)

param_grid_lr ={
    "clf__C": [0.01, 0.1, 1, 10],
    "clf__solver": ["liblinear", "lbfgs"],
}

grid_lr = GridSearchCV(
    estimator=pipe_lr,
```

```
    param_grid=param_grid_lr,
    cv=tscv,
    scoring="roc_auc",
    n_jobs=-1,
)

grid_lr.fit(X_train_raw, y_train)

best_params = grid_lr.best_params_
LR_PARAMS_1D = {k.replace("clf__", ""): v for k, v in
best_params.items()}
```

Validación interna temporal en LSTM con embargo y escalado sin fuga de información:

```
val_size_raw = int(len(X_train_raw) * 0.2)
val_start_raw = len(X_train_raw) - val_size_raw

train_end_raw = max(0, val_start_raw - H)

X_tr_raw = X_train_raw.iloc[:train_end_raw]
y_tr = y_train.iloc[:train_end_raw]

X_val_raw = X_train_raw.iloc[val_start_raw:]
y_val = y_train.iloc[val_start_raw:]


scaler = StandardScaler()
X_tr_scaled = scaler.fit_transform(X_tr_raw)
X_val_scaled = scaler.transform(X_val_raw)
X_test_scaled = scaler.transform(X_test_raw)
```

Construcción de ventanas deslizantes (lookback=10) para entrada secuencial en la LSTM:

```
def make_sequences(X: np.ndarray, y: np.ndarray, lookback: int):
    X_seq, y_seq = [], []
    for t in range(lookback - 1, len(X)):
```

```
        X_seq.append(X[t - lookback + 1:t + 1])
        y_seq.append(y[t])
    return np.asarray(X_seq, np.float32), np.asarray(y_seq,
np.int32)



lookback = 10
X_tr_seq, y_tr_seq = make_sequences(X_tr_scaled, y_tr.values,
lookback)
X_val_seq, y_val_seq = make_sequences(X_val_scaled, y_val.values,
lookback)
X_test_seq, y_test_seq = make_sequences(X_test_scaled,
y_test.values, lookback)
```

Arquitectura LSTM y configuración de entrenamiento:

```
n_features = X_tr_seq.shape[-1]


resultados_totales = []
neuronas_list = [32, 64]


for neuronas in neuronas_list:
    print (f"Entrenando modelo {MODELO_BASE} {HORIZONTE}
{SENTIMIENTO} sentimiento con {neuronas} neuronas...")
    model = models.Sequential([
        layers.Input(shape=(lookback, n_features)),
        layers.LSTM(neuronas,
return_sequences=False,kernel_regularizer=regularizers.l2(1e-4)),
        layers.Dropout(0.2),
        layers.Dense(neuronas//2, activation="relu",
kernel_regularizer=regularizers.l2(1e-4)),
        layers.Dropout(0.2),
        layers.Dense(1, activation="sigmoid")
    ])


    model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-3),
    loss="binary_crossentropy",
    metrics=[
        "accuracy",
```

```
        tf.keras.metrics.AUC(name="roc_auc", curve="ROC")])


    callbacks = [
        EarlyStopping(monitor="val_roc_auc",
mode="max",patience=10, restore_best_weights=True),
        ReduceLROnPlateau(monitor="val_roc_auc", mode="max",
factor=0.5, patience=5, min_lr=1e-5, verbose=1,)
    ]
```